

laSalle

UNIVERSITAT RAMON LLULL

**Escola Tècnica Superior d'Enginyeria
Electrònica i Informàtica La Salle**

Trabajo Final de Máster

MÁSTER BIG DATA

Evaluación Macroeconómica

Estudiantes

Lucas Alexis Morales Bahamondes
Ismael Angel Fernandez Paredes

Profesor Ponente

Mentor Externo

**ACTA DEL EXAMEN
DEL TRABAJO FINAL DE
MÁSTER**

Reunido el Tribunal calificador en la fecha indicada, los estudiantes

D. Lucas Alexis Morales Bahamondes e Ismael Angel Fernandez Paredes

expusieron su Trabajo Final de Máster, titulado:

Evaluación Macroeconómica

Acabada la exposición y contestadas por parte de los estudiantes las objeciones formuladas por los Sres. miembros del tribunal, éste valoró dicho Trabajo con la calificación de

Barcelona,

VOCAL DEL TRIBUNAL

VOCAL DEL TRIBUNAL

PRESIDENTE DEL TRIBUNAL

Resumen

ISEU+ (Índice de Salud Económica Urbana) es una plataforma de análisis económico urbano desarrollada como Trabajo de Fin de Máster cuyo objetivo es integrar, normalizar y hacer accesibles los datos socioeconómicos oficiales de las principales ciudades españolas. El proyecto responde a un problema concreto: los datos públicos sobre empleo, renta, demografía, movilidad y desigualdad existen y son de libre acceso, pero se encuentran dispersos entre diferentes organismos, publicados en formatos heterogéneos y a niveles territoriales que dificultan su comparación directa.

El sistema implementa un pipeline de datos estructurado en tres capas (Bronze, Silver y Gold) siguiendo la arquitectura medallón, con almacenamiento en Amazon S3, registro en AWS Glue Data Catalog, consulta mediante Amazon Athena y exposición de resultados a través de una función AWS Lambda sin servidor. El frontend, desplegado en Vercel, ofrece un dashboard de visualización y un chatbot conversacional que permite formular preguntas en lenguaje natural y obtener respuestas fundamentadas en los datos mediante un flujo NL2SQL impulsado por Gemini 2.5 Flash.

El sistema integra datos de tres fuentes oficiales (INE, SEPE y Open Data BCN) para siete ciudades españolas: Barcelona, Bilbao, Madrid, Málaga, Sevilla, Valencia y Zaragoza. El resultado es un total de 386.225 registros disponibles en Athena, con 93.944 indicadores normalizados que cubren 22 variables analíticas con cobertura temporal entre 2015 y 2023. El coste operativo estimado del sistema en producción es inferior a 0,30 USD mensuales gracias al modelo *serverless* basado íntegramente en servicios facturados por uso.

Palabras clave: análisis económico urbano, data lake, arquitectura medallón, AWS Athena, NL2SQL, Gemini 2.5 Flash, indicadores socioeconómicos, ciudades españolas.

Abstract

ISEU+ (Urban Economic Health Index) is an urban economic analysis platform developed as a Master's Final Project aimed at integrating, normalising and making accessible official socioeconomic data for Spain's major cities. The project addresses a concrete problem: public data on employment, income, demographics, mobility and inequality exist and are freely accessible, but are scattered across different agencies, published in heterogeneous formats and at territorial levels that make direct comparison difficult.

The system implements a three-layer data pipeline (Bronze, Silver and Gold) following the medallion architecture, with storage in Amazon S3, registration in AWS Glue Data Catalog, querying via Amazon Athena and result exposure through a serverless AWS Lambda function. The frontend, deployed on Vercel, provides a visualisation dashboard and a conversational chatbot that allows users to ask questions in natural language and receive data-grounded answers via an NL2SQL pipeline powered by Gemini 2.5 Flash.

The system integrates data from three official sources (INE, SEPE and Open Data BCN) for seven Spanish cities: Barcelona, Bilbao, Madrid, Málaga, Sevilla, Valencia and Zaragoza. The result is a total of 386,225 records available in Athena, with 93,944 normalised indicators covering 22 analytical variables with temporal coverage from 2015 to 2023.

Keywords: urban economic analysis, data lake, medallion architecture, AWS Athena, NL2SQL, Gemini 2.5 Flash, socioeconomic indicators, Spanish cities.

Acrónimos y abreviaturas

API	<i>Application Programming Interface</i> — interfaz de programación de aplicaciones
AWS	<i>Amazon Web Services</i> — plataforma de servicios en la nube de Amazon
BCN	Barcelona
CSV	<i>Comma-Separated Values</i> — formato de archivo de valores separados por comas
DDL	<i>Data Definition Language</i> — lenguaje de definición de datos SQL
DML	<i>Data Manipulation Language</i> — lenguaje de manipulación de datos SQL
ECS	<i>Elastic Container Service</i> — servicio de orquestación de contenedores de AWS
ECR	<i>Elastic Container Registry</i> — registro de imágenes Docker de AWS
ETL	<i>Extract, Transform, Load</i> — proceso de extracción, transformación y carga
IAM	<i>Identity and Access Management</i> — servicio de gestión de identidades de AWS
INE	Instituto Nacional de Estadística
ISEU+	Índice de Salud Económica Urbana (versión plus)
JSON	<i>JavaScript Object Notation</i> — formato de intercambio de datos
KPI	<i>Key Performance Indicator</i> — indicador clave de rendimiento
LLM	<i>Large Language Model</i> — modelo de lenguaje de gran tamaño
NL2SQL	<i>Natural Language to SQL</i> — traducción de lenguaje natural a SQL
NLP	<i>Natural Processing Language</i> — procesamiento del lenguaje natural
S3	<i>Simple Storage Service</i> — servicio de almacenamiento de objetos de AWS
SEPE	Servicio Público de Empleo Estatal
SQL	<i>Structured Query Language</i> — lenguaje de consulta estructurada
SSE	<i>Server-Sent Events</i> — protocolo de streaming de servidor a cliente
TFM	Trabajo de Fin de Máster
VPC	<i>Virtual Private Cloud</i> — red virtual privada en AWS

Índice general

Resumen	i
Abstract	ii
Acrónimos y abreviaturas	iii
1. Justificación e importancia de la problemática	1
1.1. Contexto: las ciudades españolas como unidad de análisis	2
1.2. El problema central: fragmentación e incompatibilidad de los datos públicos	3
1.2.1. Fragmentación por organismo productor	4
1.2.2. Fragmentación por formato y acceso	5
1.2.3. Fragmentación territorial	6
1.2.4. Fragmentación temporal	7
1.3. Limitaciones de las plataformas de análisis existentes	8
1.3.1. El Atlas de distribución de renta de los hogares (INE)	9
1.3.2. El portal de datos abiertos de la Agencia Estatal de Evaluación . .	10
1.3.3. Eurostat Urban Audit	11
1.3.4. Portales de <i>open data</i> municipales	12
1.3.5. Herramientas comerciales de inteligencia de negocio	13
1.4. Relevancia de la comparativa interurbana	14
1.4.1. Políticas públicas de empleo y renta	15
1.4.2. Movilidad y decisiones residenciales de los ciudadanos	16
1.4.3. Investigación académica en economía urbana	17
1.4.4. Transparencia y rendición de cuentas	18
1.5. La oportunidad tecnológica: Big Data y la nube como habilitadores	19

1.6.	Motivación específica del proyecto ISEU+	20
1.7.	Objetivos del proyecto	21
1.7.1.	Objetivo general	22
1.7.2.	Objetivos específicos	23
1.8.	Preguntas de investigación	24
1.9.	Alcance y delimitaciones	25
2.	Marco teórico y revisión de la literatura	26
2.1.	Big Data y análisis de datos urbanos	27
2.1.1.	El paradigma del Big Data	28
2.1.2.	Ciudades y datos: la ciudad como sistema de información	29
2.1.3.	Indicadores urbanos comparativos: experiencias internacionales	30
2.2.	Arquitecturas de datos en la nube	31
2.2.1.	El concepto de <i>data lake</i>	32
2.2.2.	La arquitectura medallón: Bronze, Silver y Gold	33
2.2.3.	Formatos de almacenamiento analítico: Parquet y Snappy	34
2.2.4.	Computación <i>serverless</i> y el modelo de pago por uso	35
2.3.	Servicios de Amazon Web Services utilizados en ISEU+	36
2.3.1.	Amazon Simple Storage Service (S3)	37
2.3.2.	AWS Glue Data Catalog	38
2.3.3.	Amazon Athena	39
2.3.4.	AWS Lambda	40
2.3.5.	Amazon Elastic Container Service y AWS Fargate	41
2.3.6.	Amazon Elastic Container Registry (ECR)	42
2.3.7.	Amazon EventBridge Scheduler	43
2.4.	Fuentes de datos oficiales	44
2.4.1.	Instituto Nacional de Estadística (INE)	45
2.4.2.	Servicio Público de Empleo Estatal (SEPE)	46
2.4.3.	Open Data BCN	47
2.5.	Modelos de lenguaje de gran tamaño e interfaces conversacionales	48
2.5.1.	Los modelos de lenguaje de gran tamaño (LLM)	49

2.5.2.	Gemini 2.5 Flash	50
2.5.3.	NL2SQL: traducción de lenguaje natural a SQL	51
2.5.4.	Prompting estructurado y generación controlada	52
2.6.	Plataformas de despliegue web: Vercel	53
2.7.	Iniciativas relacionadas y posición de ISEU+	54
2.7.1.	Comparación con plataformas de análisis urbano existentes	55
2.7.2.	Posicionamiento académico de ISEU+	56
3.	Arquitectura Cloud: Despliegue en AWS y Vercel	57
3.1.	Introducción al despliegue cloud	58
3.2.	Capa de almacenamiento: Amazon S3 y el modelo medallón	59
3.2.1.	Capa Bronze: datos crudos	60
3.2.2.	Capa Silver: datos normalizados	61
3.2.3.	Capa Gold: indicadores integrados	62
3.3.	Catálogo de datos: AWS Glue Data Catalog	63
3.4.	Motor de consulta: Amazon Athena	64
3.5.	Pipeline de datos: ECS Fargate	65
3.5.1.	Imagen Docker del pipeline	66
3.5.2.	Orquestación del pipeline	67
3.6.	Capa API: AWS Lambda	68
3.6.1.	Endpoints disponibles	69
3.6.2.	Validación y seguridad SQL	70
3.7.	Frontend: Vercel y la interfaz web de ISEU+	71
3.7.1.	Estructura del frontend	72
3.8.	Chatbot conversacional: ISEU+ con Gemini 2.5 Flash	73
3.8.1.	Descripción del esquema para el planificador SQL	74
3.8.2.	Reglas de seguridad del planificador	75
3.9.	Resultados del despliegue	76
3.10.	Estimación de costes cloud	77
3.11.	Conclusiones del despliegue cloud	78
4.	Indicadores clave de rendimiento y escenario TO-BE	79

4.1. Marco de medicion	80
4.2. Linea base AS-IS	81
4.3. KPIs urbanos de renta	82
4.3.1. Criterios de lectura de la renta	83
4.4. KPIs urbanos de desigualdad	84
4.5. KPIs urbanos de empleo	85
4.5.1. Alertas de mercado laboral	86
4.6. KPIs urbanos de demografia, movilidad y seguridad vial	87
4.7. KPIs de cobertura y completitud	88
4.8. KPIs de actualidad	89
4.9. KPIs de validez, consistencia y unicidad	90
4.10. KPIs de trazabilidad y reproducibilidad	91
4.11. KPIs operativos del pipeline	92
4.12. KPIs de consulta Athena y API	93
4.13. KPIs del chatbot NL2SQL	94
4.13.1. Latencia y experiencia conversacional	95
4.14. KPIs de producto y accesibilidad	96
4.15. KPIs de coste y eficiencia	97
4.16. Cuadro de mando de objetivos	98
4.17. Arquitectura objetivo TO-BE	99
4.18. Hoja de ruta por horizontes	100
4.19. Riesgos y respuestas	101
4.20. Gobernanza, responsables y cadencia	102
4.21. Criterios de aceptacion del escenario futuro	103
4.22. Sintesis	104

Bibliografía	105
---------------------	------------

Índice de tablas

2.1. Comparativa de plataformas de análisis urbano. <i>*La actualización mensual es la frecuencia objetivo del pipeline automatizado. La cobertura de barrio está disponible solo para Barcelona.</i>	55
3.2. Estimación de costes mensuales del sistema ISEU+ en producción. <i>Basada en el uso moderado descrito. Los servicios AWS incluidos en el nivel gratuito (Free Tier) durante los primeros 12 meses no se han contabilizado.</i>	77
4.1. Ficha minima exigida para cada KPI.	80
4.2. Linea base verificable del sistema al cierre del proyecto.	81
4.3. Objetivos TO-BE y criterios de aceptacion.	98
4.4. Matriz resumida de riesgos del TO-BE.	101

Índice de figuras

3.1. Arquitectura general del sistema ISEU+ en AWS y Vercel. <i>Flujo de datos desde la extracción (ECS Fargate) hasta la consulta conversacional (Gemini 2.5 Flash vía Vercel).</i>	58
--	----

Capítulo 1

Justificación e importancia de la problemática

1.1. Contexto: las ciudades españolas como unidad de análisis

Las ciudades concentran la mayor parte de la actividad económica, del empleo y de la población en España. Según el Instituto Nacional de Estadística (Instituto Nacional de Estadística, 2023c), más del 80 % de la población española reside en municipios de más de 10.000 habitantes, y las siete principales áreas metropolitanas —Madrid, Barcelona, Valencia, Sevilla, Zaragoza, Málaga y Bilbao— agrupan aproximadamente el 40 % del PIB nacional. Esta concentración hace que las ciudades no sean únicamente unidades administrativas, sino motores económicos cuya situación condiciona directamente la calidad de vida de millones de personas.

Sin embargo, la salud económica de una ciudad es un concepto multidimensional que no puede reducirse a un único indicador. La renta disponible media de los hogares, el nivel de desigualdad interna, la tasa de desempleo, la dinámica de creación de contratos, el acceso a servicios de movilidad o la carga de accidentes de tráfico son dimensiones que, tomadas por separado, ofrecen una imagen incompleta. Es necesario combinarlas en un sistema integrado que permita comparar territorios con equidad metodológica y con trazabilidad de las fuentes.

España dispone de una red extensa de organismos productores de estadística oficial: el INE publica datos de renta, demografía y empleo con desagregación hasta nivel de sección censal; el SEPE ofrece series mensuales de paro registrado, contratos y demandantes de empleo; los ayuntamientos de las grandes ciudades han desarrollado portales de datos abiertos con información de movilidad, servicios y actividad urbana. La información, por tanto, existe. El problema no es la ausencia de datos, sino la dificultad de integrarlos.

1.2. El problema central: fragmentación e incompatibilidad de los datos públicos

Los datos económicos oficiales de las ciudades españolas presentan cuatro tipos de fragmentación estructural que dificultan su uso conjunto (Kitchin, 2014).

1.2.1. Fragmentación por organismo productor

Cada fuente oficial —INE, SEPE, ayuntamientos, comunidades autónomas— define sus propias variables, periodicidades y niveles de desagregación geográfica de forma independiente. El INE publica la renta con cobertura hasta sección censal y frecuencia anual, mientras que el SEPE publica paro registrado con frecuencia mensual pero solo hasta nivel de municipio. Los datos municipales de Open Data BCN incluyen información de barrio con frecuencia anual o trimestral pero solo para Barcelona. No existe un marco común que permita alinear estas fuentes sin un proceso de transformación explícito.

1.2.2. Fragmentación por formato y acceso

Las fuentes oficiales no siguen un estándar común de publicación. El INE expone sus datos a través de una API REST en formato JSON-stat (Instituto Nacional de Estadística, 2022), el SEPE publica archivos de texto delimitado por comas en su sede electrónica, y los portales de datos abiertos municipales utilizan APIs propias con esquemas y paginación heterogéneos. El acceso programático requiere, en la práctica, desarrollar un conector específico para cada fuente.

1.2.3. Fragmentación territorial

Los niveles territoriales no son directamente comparables entre fuentes. El INE trabaja con secciones censales (España tiene más de 36.000), municipios (más de 8.000) y provincias (50). El SEPE agrega a nivel provincial para algunas series y municipal para otras. Los ayuntamientos publican datos por barrios o distritos con delimitaciones que no coinciden con las del INE. Esta divergencia de granularidad obliga a definir criterios explícitos de agrupación antes de cualquier comparación.

1.2.4. Fragmentación temporal

Las frecuencias de actualización varían enormemente. Mientras el SEPE publica datos de paro registrado mensualmente con un retraso de pocas semanas, el INE publica los datos de renta por sección censal con un retraso de 18 a 24 meses respecto al período de referencia. Los datos municipales de Barcelona se actualizan con frecuencias que van de lo mensual a lo anual según la variable. Esto implica que cualquier análisis comparativo debe gestionar explícitamente las fechas de referencia de cada indicador.

1.3. Limitaciones de las plataformas de análisis existentes

Existen iniciativas que han intentado abordar parcialmente el problema de la comparación interurbana en España. Sin embargo, presentan limitaciones significativas que justifican el desarrollo de ISEU+.

1.3.1. El Atlas de distribución de renta de los hogares (INE)

El INE publica el Atlas de distribución de renta de los hogares (Instituto Nacional de Estadística, 2023a), que ofrece datos de renta media, mediana y desigualdad hasta nivel de sección censal. Es una fuente de gran valor analítico, pero está limitada a las variables de renta y no permite la integración directa con indicadores de empleo, movilidad o calidad de vida. Además, no ofrece una interfaz de comparación interactiva entre ciudades.

1.3.2. El portal de datos abiertos de la Agencia Estatal de Evaluación

La AEVAL y otras agencias de evaluación publican informes periódicos sobre servicios públicos y calidad de vida, pero con frecuencia reducida, cobertura territorial limitada y sin interfaces de consulta en tiempo real.

1.3.3. Eurostat Urban Audit

El proyecto Urban Audit de Eurostat (Eurostat, 2023) ofrece comparativas entre ciudades europeas en más de 180 indicadores, pero su actualización es bienal, su cobertura de ciudades españolas se limita a las grandes áreas metropolitanas y la granularidad territorial no llega al nivel de barrio o distrito para la mayoría de variables.

1.3.4. Portales de *open data* municipales

Los portales de datos abiertos de ciudades como Barcelona, Madrid o Sevilla ofrecen información detallada sobre sus propios territorios, pero no están diseñados para la comparación interurbana. Cada portal tiene su propio esquema de datos, su propio sistema de búsqueda y sus propias convenciones de nomenclatura, lo que hace inviable la comparación directa sin un proceso de normalización.

1.3.5. Herramientas comerciales de inteligencia de negocio

Plataformas como Tableau, Power BI o Google Data Studio permiten construir dashboards comparativos, pero requieren que el usuario final realice el proceso de integración y limpieza de datos, un trabajo técnico que escapa a las capacidades del ciudadano o del investigador no especializado en ingeniería de datos (Davenport et al., 2012).

1.4. Relevancia de la comparativa interurbana

La comparación sistemática entre ciudades no es únicamente un ejercicio académico: tiene implicaciones directas para la toma de decisiones en múltiples ámbitos.

1.4.1. Políticas públicas de empleo y renta

Los organismos locales, regionales y nacionales necesitan datos comparables para diseñar y evaluar políticas de empleo y de redistribución de renta. Saber que la tasa de paro registrado de Málaga es sistemáticamente superior a la de Bilbao, y que esa diferencia se mantiene incluso después de controlar por el tamaño de la ciudad, es un insumo necesario para priorizar actuaciones territoriales. Sin embargo, esa comparación requiere series homogéneas y actualizadas que hoy no están disponibles en un formato directamente accesible.

1.4.2. Movilidad y decisiones residenciales de los ciudadanos

Los ciudadanos que se plantean cambiar de ciudad de residencia en busca de oportunidades laborales o mejores condiciones de vida necesitan información comparable. La pregunta “¿dónde vivo mejor con un salario medio?” implica comparar renta disponible, acceso al empleo, coste de vida y calidad de los servicios urbanos. Esta información existe de forma dispersa pero no está integrada en ningún sistema de consulta accesible.

1.4.3. Investigación académica en economía urbana

La economía urbana como disciplina (Glaeser, 2011) se apoya en la disponibilidad de datos comparables entre ciudades para estudiar fenómenos como la concentración del empleo cualificado, la gentrificación, las economías de aglomeración o la desigualdad intrametropolitana. En España, la disponibilidad de microdatos comparables a nivel de ciudad es limitada en comparación con otros países europeos, lo que reduce la producción científica sobre estos temas.

1.4.4. Transparencia y rendición de cuentas

Un sistema que integra y publica indicadores económicos comparables contribuye a la transparencia institucional: permite a los ciudadanos verificar si las promesas de desarrollo económico se materializan en datos reales y comparar la evolución de su ciudad respecto a otras de tamaño o características similares.

1.5. La oportunidad tecnológica: Big Data y la nube como habilitadores

La coincidencia de tres factores tecnológicos hace que sea el momento adecuado para abordar este problema con soluciones basadas en datos:

Primero, la proliferación de APIs abiertas de los organismos oficiales españoles. En los últimos años, el INE, el SEPE y numerosos ayuntamientos han publicado APIs programáticas que permiten el acceso automatizado a datos actualizados. Este acceso era técnicamente complejo o directamente imposible hace diez años.

Segundo, la madurez de las arquitecturas de datos en la nube. Servicios como Amazon S3, AWS Glue y Amazon Athena permiten construir sistemas de análisis de datos a escala con costes marginales próximos a cero para volúmenes de la magnitud que maneja ISEU+ (Armbrust et al., 2010). La curva de aprendizaje para desplegar este tipo de arquitecturas ha disminuido significativamente con la aparición de herramientas de infraestructura como código y servicios gestionados.

Tercero, la disponibilidad de modelos de lenguaje de gran tamaño (LLM) capaces de generar código SQL a partir de preguntas en lenguaje natural (Guo et al., 2019). Esta capacidad elimina la barrera técnica de acceso a los datos: el ciudadano no necesita conocer el esquema de la base de datos ni el lenguaje SQL para formular consultas complejas y obtener respuestas fundamentadas.

1.6. Motivación específica del proyecto ISEU+

ISEU+ surge de la convergencia de los problemas identificados y las oportunidades tecnológicas disponibles. El proyecto no pretende reemplazar a los organismos estadísticos oficiales —que son la fuente de verdad de los datos— sino construir una capa de integración, normalización y acceso que haga posible la comparación entre ciudades sin que el usuario tenga que realizar el trabajo de ingeniería de datos.

La hipótesis central del proyecto es que es posible construir y operar un sistema de estas características con recursos modestos —tanto económicos como computacionales— si se utilizan correctamente los servicios en la nube de pago por uso. Esta hipótesis se valida a lo largo del proyecto: el coste operativo estimado del sistema en producción, con 100 consultas diarias al chatbot y una ejecución semanal del pipeline, es inferior a 0,30 USD mensuales.

La elección de las siete ciudades iniciales —Barcelona, Bilbao, Madrid, Málaga, Sevilla, Valencia y Zaragoza— responde a su condición de capitales de provincia con más de 300.000 habitantes y a la disponibilidad de datos comparables en las fuentes seleccionadas. Esta elección no es definitiva: la arquitectura del sistema está diseñada para incorporar nuevas ciudades y nuevas fuentes sin modificar la lógica del pipeline.

1.7. Objetivos del proyecto

1.7.1. Objetivo general

Desarrollar una plataforma de análisis económico urbano basada en Big Data que integre datos oficiales de múltiples fuentes, los normalice en un modelo de indicadores comparable entre ciudades españolas y los haga accesibles mediante un interfaz conversacional en lenguaje natural con trazabilidad completa de las fuentes.

1.7.2. Objetivos específicos

1. Identificar y conectar fuentes de datos oficiales relevantes para el análisis socioeconómico de ciudades españolas, con prioridad en aquellas con acceso programático y actualización periódica.
2. Diseñar e implementar un pipeline de datos reproducible que cubra las fases de extracción, limpieza, normalización y publicación en un sistema de almacenamiento analítico en la nube.
3. Construir un modelo de indicadores que permita comparar ciudades en las dimensiones de empleo, renta, desigualdad, demografía y movilidad, con metadatos de fuente, territorio y período para cada indicador.
4. Desplegar el sistema en una arquitectura *serverless* de bajo coste sobre AWS y Vercel, que garantice disponibilidad pública sin infraestructura permanente comprometida.
5. Implementar un chatbot conversacional que responda preguntas en lenguaje natural sobre los indicadores disponibles, generando las consultas SQL necesarias de forma automática y citando la fuente, el territorio y el período de cada dato en la respuesta.
6. Validar el sistema mediante un conjunto de preguntas representativas de las necesidades de información de ciudadanos, investigadores y responsables de políticas públicas.

1.8. Preguntas de investigación

El proyecto se articula en torno a las siguientes preguntas de investigación:

1. *¿Es posible construir un sistema de comparación interurbana de indicadores económicos a partir de fuentes oficiales abiertas, con calidad metodológica suficiente para el análisis académico?*
2. *¿Puede una arquitectura serverless sobre servicios en la nube de pago por uso ofrecer disponibilidad, rendimiento y coste adecuados para un sistema de este tipo?*
3. *¿Puede un flujo NL2SQL basado en un LLM de propósito general generar consultas SQL correctas y seguras sobre un esquema de datos real, sin entrenamiento específico?*
4. *¿Qué brechas de información persisten tras integrar las fuentes disponibles y qué implicaciones tienen para la completitud del análisis?*

1.9. Alcance y delimitaciones

El alcance del proyecto se define en las siguientes dimensiones:

Territorial: el sistema cubre siete ciudades españolas (Barcelona, Bilbao, Madrid, Málaga, Sevilla, Valencia y Zaragoza) en la versión inicial. La cobertura geográfica de algunas variables es desigual: los datos de barrio solo están disponibles para Barcelona a través de Open Data BCN.

Temático: el sistema integra indicadores de empleo (paro, contratos, demandantes), renta (bruta, disponible, mediana, por hogar/persona), desigualdad (Gini, P80/P20), demografía (población total), movilidad (registros de movilidad, usuarios de bicicleta pública) y seguridad vial (accidentes de tráfico). Quedan fuera del alcance actual los datos de vivienda (precio de compra y alquiler), energía y turismo, identificados como extensiones prioritarias.

Temporal: la cobertura temporal varía por variable y fuente. El rango más amplio corresponde a los datos del SEPE (2015–2023 para paro y contratos) y del INE (2015–2021 para renta). Los datos de Open Data BCN tienen cobertura hasta 2022 para la mayoría de variables.

Técnico: el sistema se basa íntegramente en servicios gestionados de AWS y Vercel. No incluye el despliegue de infraestructura propia (servidores, bases de datos relacionales) ni el almacenamiento de datos sensibles más allá de los que las fuentes oficiales publiquen libremente.

Capítulo 2

Marco teórico y revisión de la literatura

2.1. Big Data y análisis de datos urbanos

2.1.1. El paradigma del Big Data

El concepto de Big Data fue popularizado a principios de la segunda década del siglo XXI para describir conjuntos de datos que superan la capacidad de las herramientas tradicionales de procesamiento (Laney, 2001). La definición más extendida lo caracteriza mediante las llamadas “tres V”: volumen (grandes cantidades de datos), velocidad (generación y procesamiento en tiempo real o cuasi-real) y variedad (datos estructurados, semiestructurados y no estructurados procedentes de múltiples fuentes).

Posteriormente, la literatura amplió este modelo con dos V adicionales: veracidad (calidad y fiabilidad de los datos) y valor (capacidad de extraer conocimiento útil del conjunto de datos) (IBM, 2012). Estas dimensiones son especialmente relevantes en el contexto de los datos estadísticos oficiales: el INE y el SEPE generan datos con alta veracidad pero que requieren un trabajo explícito de integración para extraer valor comparativo.

2.1.2. Ciudades y datos: la ciudad como sistema de información

La noción de *smart city* o ciudad inteligente ha promovido la idea de que los entornos urbanos pueden instrumentarse con sensores, transacciones digitales y registros administrativos para generar un flujo continuo de datos sobre su funcionamiento (Batty, 2013). Sin embargo, la mayor parte de la literatura sobre ciudades inteligentes se ha centrado en datos de tiempo real (tráfico, consumo energético, transporte público) generados por sensores o plataformas digitales, mientras que los datos estadísticos oficiales —que son más robustos metodológicamente pero de menor frecuencia— han recibido menos atención.

Kitchin (2014) plantea que la revolución de los datos no reside únicamente en el volumen o la velocidad, sino en la capacidad de combinar fuentes heterogéneas para obtener una comprensión más completa de los fenómenos sociales y económicos. Esta perspectiva es central en ISEU+: el valor del sistema no proviene de ninguna de las fuentes individuales, sino de su integración en un modelo común.

2.1.3. Indicadores urbanos comparativos: experiencias internacionales

La construcción de sistemas de indicadores comparativos entre ciudades tiene una tradición consolidada a nivel internacional. El proyecto URBAN AUDIT de Eurostat (Eurostat, 2023) es el referente más directo: recopila más de 180 indicadores para más de 900 ciudades europeas en dimensiones de demografía, mercado laboral, condiciones de vida, formación, medio ambiente y gobernanza. Sin embargo, como se indicó en el capítulo anterior, su actualización bienal y su limitada desagregación territorial para las ciudades españolas restringen su utilidad para el análisis dinámico.

El *City Health Dashboard* de la Universidad de Nueva York (Pinheiro et al., 2019) es un ejemplo de sistema que integra múltiples fuentes de datos sanitarios, económicos y ambientales para más de 500 ciudades estadounidenses, con actualización anual y visualización interactiva. La diferencia con ISEU+ radica en que este proyecto se apoya en una infraestructura institucional y un equipo de mantenimiento permanente, mientras que ISEU+ demuestra que es posible construir un sistema equivalente con recursos técnicos mínimos mediante servicios en la nube.

2.2. Arquitecturas de datos en la nube

2.2.1. El concepto de *data lake*

Un *data lake* o lago de datos es un repositorio centralizado que almacena datos en su formato original, sin imponer una estructura previa (Dixon, 2010). A diferencia de un *data warehouse* tradicional —que requiere definir el esquema antes de la carga y optimiza el almacenamiento para consultas predefinidas— un data lake acepta datos de cualquier tipo (estructurados, semiestructurados, no estructurados) y permite explorarlos, transformarlos y consultarlos *a posteriori*.

Esta flexibilidad tiene un coste: sin una metodología de organización explícita, un data lake puede convertirse en un “pantano de datos” (*data swamp*) donde la información existe pero es inaccesible por falta de metadatos, documentación o estructura (Inmon, 2016). La arquitectura medallón, descrita en la siguiente sección, es la respuesta más extendida a este problema.

2.2.2. La arquitectura medallón: Bronze, Silver y Gold

La arquitectura medallón, popularizada por Databricks (Databricks, 2021), organiza un data lake en tres capas que representan niveles crecientes de calidad y procesamiento:

Capa Bronze: almacena los datos en su estado original, tal como fueron descargados de las fuentes. No se aplica ninguna transformación: los archivos se guardan en su formato nativo (CSV, JSON, XML) con un sello de tiempo de extracción. Esta capa sirve como fuente de auditoría: si se detecta un error en fases posteriores, siempre es posible volver al dato original.

Capa Silver: contiene los datos limpiados, normalizados y estructurados. En esta fase se aplican transformaciones de estandarización (unificación de codificaciones geográficas, formatos de fecha, nombres de variables), se eliminan duplicados y se completan valores ausentes cuando es metodológicamente justificable. Los datos de la capa Silver son los que se utilizan para construir los indicadores de la capa Gold.

Capa Gold: almacena los indicadores finales, listos para el análisis y la presentación. Los datos de esta capa están optimizados para ser consumidos por el motor de consulta (Athena) y por el frontend del sistema. La capa Gold es la que expone el valor analítico del sistema.

La adopción de la arquitectura medallón en ISEU+ garantiza que cualquier cambio en las fuentes o en la lógica de transformación puede propagarse de forma controlada capa a capa, sin perder el registro de los datos originales.

2.2.3. Formatos de almacenamiento analítico: Parquet y Snappy

La elección del formato de almacenamiento tiene implicaciones directas sobre el rendimiento y el coste de las consultas analíticas. Los formatos orientados a columnas, como Apache Parquet (Apache Software Foundation, 2023), almacenan los valores de cada columna de forma contigua en disco, lo que permite a los motores de consulta leer únicamente las columnas necesarias para responder a una pregunta, sin cargar las filas completas.

En el contexto de Athena, donde el coste se mide por los datos escaneados (5 USD por terabyte), la compresión columnar de Parquet puede reducir el volumen de datos leído en un factor de 10 a 20 respecto a un archivo CSV equivalente. El algoritmo de compresión Snappy, elegido en ISEU+, ofrece una relación equilibrada entre velocidad de descompresión y ratio de compresión, lo que lo hace idóneo para consultas interactivas donde la latencia es un factor crítico.

2.2.4. Computación *serverless* y el modelo de pago por uso

El modelo *serverless* o sin servidor se refiere a arquitecturas en las que el proveedor de nube gestiona automáticamente el aprovisionamiento, el escalado y la administración de la infraestructura de cómputo (Roberts, 2018). El desarrollador solo proporciona el código de la función o la lógica del contenedor; la infraestructura subyacente es completamente opaca.

Este modelo tiene dos ventajas fundamentales para proyectos como ISEU+: primero, elimina el coste de infraestructura en períodos de inactividad —una Lambda que no recibe peticiones no genera coste computacional—; segundo, escala automáticamente ante picos de demanda sin intervención manual. La contrapartida es el llamado “arranque en frío” (*cold start*): la primera invocación de una función tras un período de inactividad incurre en una latencia adicional de inicialización, generalmente inferior a un segundo para funciones Python de tamaño reducido.

2.3. Servicios de Amazon Web Services utilizados en ISEU+

2.3.1. Amazon Simple Storage Service (S3)

Amazon S3 es el servicio de almacenamiento de objetos de AWS (Amazon Web Services, 2023f). A diferencia de un sistema de archivos tradicional, S3 no organiza los datos en directorios con estructura jerárquica real: cada objeto se identifica mediante una clave única (una ruta arbitraria) dentro de un *bucket*. Sin embargo, es posible simular una estructura de directorios utilizando el carácter de separación de ruta en las claves, lo que permite organizar los objetos de forma intuitiva.

Las características más relevantes de S3 para ISEU+ son:

- **Durabilidad:** S3 garantiza una durabilidad del 99,999999999 % (once nueves) mediante replicación automática entre al menos tres zonas de disponibilidad dentro de la región.
- **Escalabilidad:** no existe límite práctico en el volumen de datos que puede almacenar un bucket. El coste es proporcional al almacenamiento efectivo (aproximadamente 0,023 USD por GB/mes en la clase de almacenamiento estándar).
- **Integración nativa con el ecosistema AWS:** S3 es el punto de integración central entre Glue, Athena, Lambda y ECS, lo que simplifica enormemente la arquitectura de datos.
- **Políticas de ciclo de vida:** es posible definir reglas automáticas que transicionen los objetos a clases de almacenamiento más baratas (S3 Intelligent-Tiering, S3 Glacier) después de un período de inactividad, reduciendo el coste de almacenamiento de datos históricos.

2.3.2. AWS Glue Data Catalog

AWS Glue es un servicio de integración de datos que incluye, entre otros componentes, el Glue Data Catalog (Amazon Web Services, 2023g): un repositorio centralizado de metadatos que describe la estructura de los datos almacenados en S3. Funciona como un metastore compatible con Apache Hive, lo que lo hace directamente utilizable por Athena, Amazon EMR y otros servicios del ecosistema Hadoop/Spark.

El catálogo registra para cada tabla: el esquema de columnas con sus tipos de dato, la localización física de los datos en S3, el formato de serialización (Parquet, ORC, CSV, JSON...) y las propiedades de particionamiento. Esta información permite a Athena ejecutar consultas SQL sobre archivos S3 sin necesidad de cargar los datos en una base de datos relacional.

La API de Glue permite registrar y actualizar tablas de forma programática, lo que se aprovecha en el pipeline de ISEU+ para actualizar el catálogo automáticamente cada vez que el pipeline de datos publica una nueva versión de los indicadores en S3.

2.3.3. Amazon Athena

Amazon Athena es un motor de consulta SQL sin servidor que analiza datos directamente en Amazon S3 (Amazon Web Services, 2023d). Se basa en el motor de código abierto Trino (anteriormente conocido como PrestoSQL), lo que lo hace compatible con el estándar ANSI SQL y con extensiones avanzadas como funciones de ventana (*window functions*), expresiones regulares, operaciones con fechas y tipos de dato complejos (arrays, maps).

Las características de Athena más relevantes para ISEU+ son:

- **Modelo de coste:** Athena factura exclusivamente por los datos escaneados en cada consulta (5 USD por terabyte). Para el volumen de datos de ISEU+ (aproximadamente 500 MB en formato Parquet), el coste por consulta es inferior a 0,001 USD.
- **Sin infraestructura persistente:** no hay instancias de base de datos que mantener o escalar. Athena aprovisiona y libera recursos de cómputo automáticamente para cada consulta.
- **Workgroups:** Athena permite organizar las consultas en grupos de trabajo con límites de coste, configuración de resultados y políticas de acceso independientes. ISEU+ utiliza el workgroup `iseu` para aislar las consultas del sistema del resto de la cuenta AWS.
- **Concurrencia:** Athena puede ejecutar múltiples consultas en paralelo sin límite explícito para el plan estándar, lo que permite que el endpoint `/dashboard` lance hasta 15 consultas simultáneas mediante `ThreadPoolExecutor`.

2.3.4. AWS Lambda

AWS Lambda es el servicio de computación sin servidor de AWS (Amazon Web Services, 2023h). Permite ejecutar funciones de código arbitrario en respuesta a eventos (peticiones HTTP, mensajes en cola, cambios en S3) sin aprovisionar ni gestionar servidores. La función se ejecuta en un entorno de ejecución gestionado por AWS, que garantiza aislamiento entre invocaciones y escala automáticamente.

Las funciones Lambda se facturan por número de invocaciones (1 millón de invocaciones gratuitas al mes en el nivel gratuito permanente) y por tiempo de ejecución (medido en GB-segundos, donde GB es la memoria asignada). Para una función con 512 MB de memoria y un tiempo de ejecución medio de 3 segundos por consulta, el coste de 3.000 consultas diarias sería inferior a 0,01 USD mensuales.

El principal desafío de Lambda para consultas interactivas es el llamado “arranque en frío”: cuando una función no ha recibido tráfico durante un período de tiempo, el entorno de ejecución es liberado y la siguiente invocación debe inicializar el proceso Python, importar las dependencias y establecer las conexiones con los servicios AWS. En ISEU+, el arranque en frío tiene un impacto acotado porque el handler utiliza `lru_cache` para almacenar en caché la lista de tablas del catálogo Glue durante el ciclo de vida del contenedor de ejecución.

2.3.5. Amazon Elastic Container Service y AWS Fargate

Amazon ECS (Amazon Web Services, 2023a) es el servicio de orquestación de contenedores de AWS. Permite definir tareas (*tasks*) que ejecutan uno o más contenedores Docker con una configuración declarativa: imagen, recursos de CPU y memoria, variables de entorno, roles IAM y configuración de red. Las tareas ECS pueden ejecutarse sobre instancias EC2 administradas por el usuario o mediante AWS Fargate, que elimina completamente la necesidad de gestionar la infraestructura de las instancias.

AWS Fargate (Amazon Web Services, 2023c) es un motor de ejecución de contenedores sin servidor: el usuario define la tarea y Fargate aprovisiona, gestiona y libera la infraestructura de cómputo de forma automática. La facturación es por vCPU y memoria asignadas durante el tiempo de ejecución de la tarea. Para una tarea con 0,5 vCPU, 1 GB de RAM y 30 minutos de ejecución, el coste es aproximadamente 0,05 USD.

En ISEU+, ECS Fargate se utiliza para ejecutar el pipeline de datos completo (extracción, limpieza, construcción de Gold y publicación en Athena) de forma periódica o bajo demanda. La tarea se define en la *task definition* `iseu-pipeline` y se puede disparar mediante la CLI de AWS, la consola web o Amazon EventBridge Scheduler.

2.3.6. Amazon Elastic Container Registry (ECR)

Amazon ECR (Amazon Web Services, 2023e) es el servicio de registro de imágenes Docker de AWS. Almacena las imágenes del contenedor del pipeline en un repositorio privado dentro de la misma cuenta y región AWS que los demás servicios, eliminando la latencia y el coste de descarga de imágenes desde registros externos (como Docker Hub) durante el arranque del contenedor.

2.3.7. Amazon EventBridge Scheduler

Amazon EventBridge Scheduler (Amazon Web Services, 2023b) permite programar la ejecución de tareas AWS (Lambda, ECS, Step Functions...) mediante expresiones *cron* o frecuencias periódicas. En ISEU+, se utiliza para disparar el pipeline de datos mensualmente, sincronizado con los calendarios de publicación del INE y el SEPE.

2.4. Fuentes de datos oficiales

2.4.1. Instituto Nacional de Estadística (INE)

El Instituto Nacional de Estadística es el organismo oficial de estadística de España, responsable de la planificación, dirección y coordinación de las actividades estadísticas de la Administración General del Estado (Instituto Nacional de Estadística, 2023b). Para ISEU+, las operaciones estadísticas del INE más relevantes son:

El Atlas de distribución de renta de los hogares: publicado anualmente con datos de renta bruta, renta disponible, renta mediana y desigualdad (índice de Gini y relación P80/P20) desagregados hasta nivel de sección censal para todos los municipios de más de 1.000 habitantes. La metodología combina datos de declaraciones del IRPF, prestaciones de la Seguridad Social y contrastes con la Encuesta de Condiciones de Vida para cubrir la población no declarante.

El Padrón Municipal de Habitantes: proporciona datos de población a nivel de municipio y sección censal, con actualización anual. Es la fuente de referencia para la variable `Poblacion total` en ISEU+.

La API del INE (Instituto Nacional de Estadística, 2022) permite el acceso programático a más de 3.000 operaciones estadísticas mediante peticiones HTTP que devuelven datos en formato JSON-stat (JSON-stat, 2023). JSON-stat es un formato de intercambio de datos estadísticos multidimensionales que organiza los valores en un array lineal junto con los metadatos que describen las dimensiones (territorios, períodos, variables). El conector del INE en ISEU+ implementa la decodificación de este formato para extraer las series temporales de interés.

2.4.2. Servicio Público de Empleo Estatal (SEPE)

El SEPE es el organismo autónomo del Ministerio de Trabajo y Economía Social responsable de gestionar las prestaciones por desempleo y los programas de empleo en España (Servicio Público de Empleo Estatal, 2023). Publica mensualmente estadísticas de:

- **Paro registrado:** número de personas inscritas en las oficinas de empleo como demandantes de empleo no ocupadas, desagregado por municipio, sector de actividad, edad y sexo.
- **Contratos registrados:** número de contratos de trabajo comunicados al sistema de registro de contratos, desagregado por municipio, tipo de contrato y sector.
- **Demandantes de empleo:** número total de personas inscritas en las oficinas de empleo, incluyendo tanto parados como trabajadores que buscan empleo adicional.

Los datos del SEPE se publican en archivos de texto con separador de campo en la sede electrónica del organismo, con un retraso habitual de 15 a 30 días respecto al mes de referencia. El conector del SEPE en ISEU+ descarga estos archivos, los decodifica con la codificación correcta (ISO-8859-1) y extrae las series temporales para las siete ciudades del sistema.

2.4.3. Open Data BCN

Open Data BCN (Ajuntament de Barcelona, 2023) es el portal de datos abiertos del Ayuntamiento de Barcelona, uno de los portales de datos municipales más completos de España. Ofrece más de 500 conjuntos de datos en categorías que incluyen economía, demografía, transporte, medio ambiente, turismo y servicios urbanos.

Para ISEU+, Open Data BCN es la fuente de los indicadores de movilidad, accidentes de tráfico y usuarios de bicicleta pública, con desagregación hasta nivel de barrio y frecuencia anual. Los datos se acceden mediante la API CKAN (Comprehensive Knowledge Archive Network), que devuelve los recursos en formato CSV o JSON. Open Data BCN es la única fuente del sistema con cobertura a nivel de barrio; el resto de fuentes (INE y SEPE) solo tienen cobertura hasta nivel de municipio o ciudad para las variables integradas.

2.5. Modelos de lenguaje de gran tamaño e interfaces conversacionales

2.5.1. Los modelos de lenguaje de gran tamaño (LLM)

Los modelos de lenguaje de gran tamaño son sistemas de inteligencia artificial entrenados sobre corpus masivos de texto para predecir la distribución de probabilidad de las palabras en una secuencia (Brown et al., 2020). Su capacidad para generar texto coherente y contextualmente relevante los ha convertido en la base de aplicaciones conversacionales, sistemas de ayuda a la codificación, motores de traducción y, más recientemente, interfaces de acceso a datos estructurados.

La arquitectura *Transformer* (Vaswani et al., 2017), presentada en 2017, es la base de todos los LLM modernos de relevancia. Sus mecanismos de atención permiten al modelo relacionar palabras distantes en el contexto de entrada, capturando dependencias a larga distancia que las arquitecturas recurrentes anteriores no podían modelar eficientemente.

2.5.2. Gemini 2.5 Flash

Gemini 2.5 Flash es el modelo de lenguaje de Google utilizado en ISEU+ (Google, 2024). Pertenecce a la familia Gemini, diseñada para ser eficiente en latencia y coste sin sacrificar capacidad de razonamiento. Sus características más relevantes para el sistema son:

- Ventana de contexto de hasta 1 millón de tokens, lo que permite incluir el esquema completo de la base de datos, el historial de la conversación y los resultados de las consultas en un único *prompt*.
- Capacidad de generación de código SQL correcto para diferentes dialectos, incluido Trino/Athena.
- Soporte de esquemas JSON estructurados (*responseJsonSchema*) para forzar que las respuestas del planificador SQL sigan un formato estrictamente validable.
- API de *streaming* mediante Server-Sent Events, que permite mostrar la respuesta al usuario a medida que se genera, reduciendo la percepción de latencia.

2.5.3. NL2SQL: traducción de lenguaje natural a SQL

La tarea de NL2SQL consiste en generar automáticamente una consulta SQL válida a partir de una pregunta formulada en lenguaje natural (Guo et al., 2019). Es una de las aplicaciones más investigadas de los LLM aplicados a datos estructurados, con benchmarks como Spider (Yu et al., 2018) y BIRD (Li et al., 2023) que miden la precisión de los sistemas sobre esquemas de base de datos de creciente complejidad.

La principal dificultad del NL2SQL es la ambigüedad del lenguaje natural frente a la precisión requerida por SQL. Preguntas como “¿cuánto gana de media la gente en Barcelona?” pueden interpretarse como promedio de renta bruta, renta disponible o renta por hogar, y la elección incorrecta devuelve un resultado numéricamente diferente. Los sistemas más avanzados abordan esta ambigüedad mediante: (1) la inclusión de descripciones semánticas de las columnas en el *prompt* del planificador; (2) la generación de planes de consulta intermedios que el LLM justifica antes de generar el SQL; y (3) la validación automática de la consulta antes de ejecutarla.

ISEU+ implementa las tres estrategias: el `SCHEMA_DESCRIPTION` incluye las equivalencias entre nombres de variable en inglés (en la tabla `indicators`) y en español (en la tabla `indicadores`); el planificador genera un objeto JSON con campos `needs_data`, `sql` y `reason` antes de ejecutar la consulta; y el handler Lambda valida la consulta contra un conjunto de restricciones antes de enviarla a Athena.

2.5.4. Prompting estructurado y generación controlada

Una de las técnicas más efectivas para mejorar la calidad del NL2SQL con LLM es el *prompting estructurado*: en lugar de pedir directamente “genera el SQL para esta pregunta”, el sistema descompone la tarea en subproblemas más pequeños y más fácilmente verificables (Wei et al., 2022).

En ISEU+, el planificador SQL recibe en su *prompt*: la pregunta del usuario, la fecha actual del sistema, el historial reciente de la conversación, la descripción completa del esquema (tablas, columnas, valores posibles de la columna **variable**) y un conjunto de reglas explícitas sobre cuándo usar cada tabla, qué nombres exactos de variable emplear y qué patrones SQL son obligatorios en cada caso (por ejemplo, el uso de **GROUP BY city** para preguntas comparativas).

La respuesta del planificador se fuerza a seguir un esquema JSON validado (**responseJson-Schema**), lo que garantiza que el campo **needs_data** sea siempre un booleano y el campo **sql** sea siempre una cadena, independientemente de la redacción de la pregunta.

2.6. Plataformas de despliegue web: Vercel

Vercel (Vercel, 2023) es una plataforma de despliegue continuo especializada en aplicaciones web estáticas y funciones *serverless*. Su modelo de trabajo está centrado en la integración con repositorios de código (GitHub, GitLab, Bitbucket): cada *push* a la rama principal desencadena automáticamente la compilación, el despliegue y la asignación de una URL permanente a la nueva versión.

Las funciones *serverless* de Vercel (*Serverless Functions*) permiten ejecutar código Python, Node.js o Go en el servidor sin gestionar infraestructura. Cada función se despliega como un proceso aislado que se invoca en respuesta a peticiones HTTP, con un tiempo de arranque típico inferior a 500 ms y un tiempo de ejecución máximo de 60 segundos en el plan gratuito (plan Hobby).

Para ISEU+, Vercel sirve el contenido estático (HTML, CSS, JavaScript) directamente desde su CDN global, con latencia inferior a 50 ms para usuarios en Europa, y ejecuta las funciones Python del API (`api/chat.py`, `api/dashboard.py`, `api/health.py`) como *serverless functions* en la región de Europa Occidental.

2.7. Iniciativas relacionadas y posición de ISEU+

2.7.1. Comparación con plataformas de análisis urbano existentes

La Tabla 2.1 resume las principales características de las iniciativas de análisis urbano comparativo existentes frente a ISEU+.

Plataforma	Cobertura	Variables	Geo.	Frecuencia	NL
Eurostat Urban Audit	Europea (900+ ciudades)	180+	Ciudad	Bienal	No
INE Atlas de Renta	España (sección censal)	10 (renta)	Sección censal	Anual	No
Open Data BCN	Barcelona	500+	Barrio	Variable	No
City Health Dashboard	EE.UU. (500 ciudades)	40	Ciudad	Anual	No
ISEU+	7 ciudades ES	22	Ciudad y barrio	Mensual*	Sí

Tabla 2.1

Comparativa de plataformas de análisis urbano.

**La actualización mensual es la frecuencia objetivo del pipeline automatizado. La cobertura de barrio está disponible solo para Barcelona.*

2.7.2. Posicionamiento académico de ISEU+

ISEU+ se posiciona en la intersección de tres áreas de conocimiento: la ingeniería de datos (diseño del pipeline y la arquitectura en la nube), la economía urbana (selección y construcción de indicadores comparativos) y la inteligencia artificial aplicada (NL2SQL con LLM). Esta interdisciplinariedad es al mismo tiempo su fortaleza —combina capacidades de áreas distintas— y su limitación académica: el rigor metodológico en cada área individual es menor del que podría alcanzarse en un proyecto especializado.

La principal contribución académica del proyecto no radica en el desarrollo de nuevas técnicas, sino en la demostración de que la integración de servicios en la nube maduros (S3, Athena, Lambda) con LLM de propósito general (Gemini 2.5 Flash) permite construir sistemas de análisis de datos comparativos con cobertura real, disponibilidad pública y coste operativo mínimo, sin necesidad de infraestructura dedicada ni equipos especializados en mantenimiento.

Capítulo 3

Arquitectura Cloud: Despliegue en AWS y Vercel

3.1. Introducción al despliegue cloud

La fase local de ISEU+ permitió validar el modelo de datos, los conectores de fuentes oficiales y la lógica analítica del sistema. Una vez comprobada la coherencia del pipeline y la calidad de los indicadores generados, el proyecto migró a una arquitectura en la nube orientada a producción. El objetivo de esta transición no fue únicamente trasladar el código a servidores remotos, sino rediseñar el sistema para que pudiera ejecutarse de forma autónoma, escalarse ante picos de carga y estar accesible desde cualquier dispositivo con conexión a Internet.

La arquitectura cloud de ISEU+ se sustenta en tres pilares: (1) un *data lake* estructurado en Amazon S3 con las capas Bronze, Silver y Gold del modelo medallón; (2) una capa de procesamiento orquestada mediante AWS Elastic Container Service (ECS) con tareas Fargate; y (3) una capa de servicio compuesta por Amazon Athena como motor de consulta SQL, AWS Lambda como API sin servidor y Vercel como plataforma de despliegue del frontend. La Figura 3.1 sintetiza los componentes y el flujo de datos entre ellos.




Figura 3.1

Arquitectura general del sistema ISEU+ en AWS y Vercel.

Flujo de datos desde la extracción (ECS Fargate) hasta la consulta conversacional (Gemini 2.5 Flash vía Vercel).

3.2. Capa de almacenamiento: Amazon S3 y el modelo medallón

El almacenamiento central de ISEU+ se implementó en el bucket oficial del proyecto en Amazon S3, siguiendo la arquitectura medallón en tres capas diferenciadas por nivel de procesamiento y calidad del dato. Su identificador y región se mantienen como configuración operativa del despliegue.

3.2.1. Capa Bronze: datos crudos

La capa Bronze almacena los archivos originales descargados de las fuentes oficiales sin ninguna transformación. Los datos se organizan por fuente y fecha de extracción bajo el prefijo `s3://iseu-datalake-ismael-2026/bronze/`. Esta capa actúa como registro de auditoría inmutable: cualquier error en fases posteriores del pipeline puede trazarse hasta el dato original descargado.

3.2.2. Capa Silver: datos normalizados

La capa Silver contiene los datos limpios y normalizados tras aplicar las transformaciones de estandarización de variables, codificación geográfica y control de calidad. Los archivos se almacenan en formato Parquet comprimido con Snappy bajo el prefijo `silver/athena/`, siguiendo el esquema esperado por AWS Glue para su registro automático en el catálogo de datos. Las tablas Silver registradas en el sistema incluyen datos brutos de los módulos SEPE, INE y Municipal Open Data:

- `iseu_silver_sepe_paro_registrado`: evolución mensual del paro registrado por ciudad.
- `iseu_silver_sepe_contratos_registrados`: contratos firmados por período y territorio.
- `iseu_silver_sepe_demandantes_empleo`: demandantes de empleo activos por período.
- `iseu_silver_ine_poblacion_municipal`: población de referencia por municipio.
- `iseu_silver_municipios_municipal_prioritario`: datos socioeconómicos municipales del INE con 243 variables y 167.725 registros.

3.2.3. Capa Gold: indicadores integrados

La capa Gold contiene las tablas analíticas finales, construidas a partir de la Silver tras una segunda fase de enriquecimiento y agregación. Es el nivel de datos que consume directamente el motor de consulta y el chatbot. Se definen tres tablas Gold registradas en Athena:

- **iseu_indicadores**: tabla principal con 93.944 registros de indicadores normalizados, 22 variables y cobertura temporal 2015-2023. Es la fuente primaria del sistema analítico.
- **iseu_semantic_obs**: tabla de observaciones semánticas con 105.774 registros enriquecidos con jerarquía ciudad–distrito–barrio, notas contextuales y granularidad geográfica.
- **iseu_indicators**: tabla Gold compacta con 4.358 registros agregados a nivel de ciudad para comparativas rápidas.

La elección de Parquet como formato de almacenamiento responde a sus características de compresión columnar, optimizadas para las consultas analíticas de Athena: filtros por columna sin leer filas enteras, compresión Snappy que reduce el volumen de datos escaneados y soporte nativo en el ecosistema Hadoop/Hive sobre el que se apoya Glue.

3.3. Catálogo de datos: AWS Glue Data Catalog

AWS Glue Data Catalog actúa como metastore centralizado del sistema. Registra la estructura de cada tabla Parquet en S3: esquema de columnas, tipos de datos, localización física en el bucket y propiedades del formato de serialización. Esta capa de metadatos permite que Amazon Athena ejecute consultas SQL estándar directamente sobre los archivos S3 sin necesidad de un motor de base de datos tradicional.

El catálogo se organiza bajo la base de datos lógica `iseu`, que agrupa todas las tablas del sistema (Silver y Gold). El handler de la Lambda consulta el catálogo en cada arranque en frío para detectar dinámicamente las tablas disponibles, lo que permite incorporar nuevas fuentes de datos sin modificar el código de la API.

La función `table_names()` implementa esta detección dinámica con caché `lru_cache` para minimizar las llamadas al catálogo durante el ciclo de vida de la función Lambda:

```
@lru_cache(maxsize=1)
def table_names() -> dict[str, str | None]:
    paginator = glue.get_paginator("get_tables")
    found = {alias: None for alias in _TABLE_LOCATIONS}
    for page in paginator.paginate(DatabaseName=DATABASE):
        for table in page.get("TableList", []):
            name = table["Name"]
            location = table.get("StorageDescriptor", {}) \
                .get("Location", "").lower()
            for alias, fragment in _TABLE_LOCATIONS.items():
                if fragment in location and found[alias] is None:
                    found[alias] = name
            if "silver/athena/" in location:
                found[f"silver_{name}"] = name
    return found
```

3.4. Motor de consulta: Amazon Athena

Amazon Athena es el motor SQL sin servidor que permite ejecutar consultas sobre los archivos Parquet almacenados en S3. Athena adopta el dialecto Trino (anteriormente PrestoSQL), compatible con ANSI SQL y con extensiones para funciones de ventana, expresiones regulares y tipos de dato nativos de Hive.

La elección de Athena frente a alternativas como Amazon Redshift o una base de datos relacional clásica responde a tres criterios:

1. **Modelo de coste por uso:** Athena factura únicamente los datos escaneados por cada consulta (5 USD por terabyte). Para el volumen actual de ISEU+ (aproximadamente 386.000 registros en total), el coste por consulta es inferior a un céntimo de euro.
2. **Ausencia de infraestructura persistente:** no requiere mantener instancias de base de datos activas fuera de los períodos de consulta.
3. **Integración nativa con S3 y Glue:** Athena lee directamente los Parquet registrados en el catálogo sin operaciones de carga o importación.

Las consultas del sistema se ejecutan mediante el SDK de Python (`boto3`), con un timeout configurable de 22 segundos y un sistema de *polling* que comprueba el estado de ejecución cada 250 milisegundos. Los resultados se paginan en bloques de 1.000 filas para evitar timeouts en consultas con retornos amplios.

3.5. Pipeline de datos: ECS Fargate

El pipeline de transformación de datos se ejecuta en un contenedor Docker desplegado mediante AWS Elastic Container Service (ECS) con el motor Fargate. Fargate es una modalidad de ejecución sin servidor para contenedores: el usuario define la tarea y AWS aprovisiona, gestiona y libera la infraestructura de cómputo de forma automática.

3.5.1. Imagen Docker del pipeline

La imagen del pipeline se construye a partir de `python:3.12-slim` e instala las dependencias de extracción, transformación y publicación a S3:

```
FROM python:3.12-slim
WORKDIR /app
COPY requirements.txt .
RUN pip install --no-cache-dir -r requirements.txt
COPY . .
CMD ["python", "-m", "apisVcloud.cloud_pipeline"]
```

La imagen se publica en Amazon Elastic Container Registry (ECR) y queda referenciada en la definición de tarea ECS. La definición desplegada asigna 1 vCPU y 4 GB de RAM, además de las variables de entorno y los roles IAM que separan la ejecución del contenedor del acceso de la tarea a S3.

3.5.2. Orquestación del pipeline

El orquestador `cloud_pipeline.py` ejecuta el flujo completo de transformación en cuatro etapas secuenciales:

1. **Collect:** descarga datos actualizados de las APIs oficiales (INE, SEPE, Open Data BCN) y los almacena en la capa Bronze de S3.
2. **Clean:** aplica las transformaciones de limpieza y normalización, generando la capa Silver.
3. **Build SQLite:** consolida los datos Silver en una base SQLite transitoria con las tablas `indicadores`, `indicators` y `semantic_observations`.
4. **Export Athena:** convierte las tablas SQLite a formato Parquet, las sube a la capa Gold de S3 y actualiza el AWS Glue Data Catalog.

La ejecución puede dispararse manualmente mediante la CLI de AWS y se encuentra programada mediante Amazon EventBridge Scheduler el día 1 de cada mes a las 07:00, zona **Europe/Madrid**, con dos reintentos. El sistema opera en la región **eu-west-1** (Irlanda), usando subredes públicas e IP pública para alcanzar las APIs externas sin asumir el coste fijo de una pasarela NAT; el contenedor no publica puertos de entrada.

3.6. Capa API: AWS Lambda

La interfaz de acceso a los datos desde el frontend se implementa mediante una función AWS Lambda (`iseu-athena-query`) escrita en Python 3.12. Lambda es el servicio de computación sin servidor de AWS: el código se ejecuta únicamente cuando recibe una petición, sin infraestructura persistente, con arranque en frío de menos de un segundo y facturación por milisegundo de ejecución.

3.6.1. Endpoints disponibles

La función Lambda expone cuatro endpoints accesibles a través de Amazon API Gateway:

- **GET /health:** verificación de disponibilidad del servicio.
- **GET /dashboard:** construye y devuelve el payload completo del dashboard, incluyendo KPIs agregados, distribución por fuente, evolución temporal, calidad de datos y catálogo de variables. Lanza hasta 15 consultas Athena en paralelo mediante `ThreadPoolExecutor`.
- **GET /catalog:** catálogo de fuentes y variables disponibles en el sistema.
- **POST /sql:** ejecuta una consulta SQL arbitraria sobre las tablas permitidas. La consulta pasa por un validador que verifica que sea un **SELECT**, que no contenga comentarios ni instrucciones DDL/DML, y que solo referencie las tablas autorizadas (`indicators`, `indicadores`, `observations`).

3.6.2. Validación y seguridad SQL

El endpoint `/sql` implementa un validador que previene inyecciones y limita el acceso a las operaciones de lectura autorizadas. El validador rechaza consultas que contengan palabras reservadas de modificación (`INSERT`, `UPDATE`, `DELETE`, `DROP`, `ALTER`), comentarios SQL (`-`, `/* */`) o referencias a tablas no incluidas en la lista de permitidas. Además, impone un `LIMIT 500` máximo para evitar la transferencia de volúmenes excesivos de datos.

3.7. Frontend: Vercel y la interfaz web de ISEU+

La capa de presentación del sistema se despliega en Vercel, una plataforma de despliegue continuo orientada a aplicaciones web estáticas y funciones serverless. Vercel ofrece integración directa con GitHub: cada *push* a la rama principal desencadena automáticamente la compilación y publicación de la nueva versión, con un tiempo de despliegue inferior a 30 segundos.

3.7.1. Estructura del frontend

La interfaz web se compone de dos páginas HTML estáticas:

- **Dashboard** (`dashboard.html`): presenta los KPIs del sistema (número de indicadores, variables, fuentes y registros de detalle), distribución geográfica de los datos, calidad por fuente, evolución temporal y catálogo de variables. Los datos se obtienen dinámicamente llamando al endpoint `/api/dashboard` de la Lambda mediante una petición `fetch` al cargar la página.
- **Chatbot** (`chatbot.html`): interfaz conversacional en lenguaje natural con tres vistas de respuesta: General (texto), Tablas (filas reales de la consulta Athena) y Gráficos (visualizaciones auto-detectadas). El módulo de gráficos analiza las columnas de los resultados SQL para seleccionar automáticamente entre serie temporal (gráfico de línea) y comparativa categórica (gráfico de barras).

Las llamadas al API de datos se enrutan a través de funciones Python desplegadas en Vercel (`api/dashboard.py`, `api/chat.py`, `api/health.py`), que actúan como intermediarios entre el frontend y los servicios AWS.

3.8. Chatbot conversacional: ISEU+ con Gemini 2.5 Flash

El módulo conversacional de ISEU+ implementa un flujo NL2SQL (*Natural Language to SQL*) en dos fases mediante el modelo Gemini 2.5 Flash de Google. El flujo completo se ejecuta en el servidor Vercel sin mantener estado entre peticiones:

1. **Planificación SQL:** el sistema envía a Gemini la pregunta del usuario, el historial reciente de la conversación y una descripción estructurada del esquema de datos (tablas, columnas, variables disponibles y sus equivalencias en español e inglés). Gemini devuelve un objeto JSON con tres campos: **needs_data** (booleano), **sql** (la consulta generada) y **reason** (justificación de la elección de tabla y variables).
2. **Ejecución y respuesta:** si **needs_data** es verdadero, el sistema llama al endpoint `/sql` de la Lambda para ejecutar la consulta en Athena. Los resultados (máximo 100 filas) se incorporan como evidencia al segundo prompt enviado a Gemini, que genera la respuesta final en español con trazabilidad de fuente, territorio y período.

El sistema implementa dos modos de respuesta: *streaming* (SSE, *Server-Sent Events*) para mostrar la respuesta en tiempo real mientras Gemini la genera, y modo estándar JSON para compatibilidad con clientes que no soporten streaming.

3.8.1. Descripción del esquema para el planificador SQL

Un elemento crítico del sistema es la descripción del esquema que recibe el modelo de lenguaje. Esta descripción incluye el nombre de cada tabla, sus columnas con tipos de dato, los valores posibles de las columnas clave (especialmente **variable** y **geo**) y las reglas de selección entre tablas. Para la tabla **indicadores**, el sistema especifica los 22 nombres exactos de variable en español para que el modelo los reproduzca literalmente en la cláusula **WHERE**, evitando errores de coincidencia parcial.

3.8.2. Reglas de seguridad del planificador

Para garantizar que las consultas generadas sean correctas y seguras, el planificador SQL recibe restricciones explícitas: prohibición de CTEs, JOINS, DDL, DML y comentarios; uso de `GROUP BY` obligatorio cuando la pregunta compara múltiples entidades; patrón `row_number() OVER (PARTITION BY ...)` para recuperar el registro más reciente de cada ciudad; y un `LIMIT` máximo de 100 filas. El validador de la Lambda actúa como segunda línea de defensa: cualquier consulta que supere estas restricciones es rechazada antes de alcanzar Athena.

3.9. Resultados del despliegue

Tras la migración a la arquitectura cloud, el sistema ISEU+ presenta los siguientes indicadores de resultado:

Indicador	Valor
Total de registros en Athena	386.225 filas
Indicadores normalizados (<code>iseu_indicadores</code>)	93.944 registros
Observaciones semánticas (<code>iseu_semantic_obs</code>)	105.774 registros
Variables analíticas disponibles	22 variables
Ciudades cubiertas	7 (Barcelona, Bilbao, Madrid, Málaga, Sevilla, Valencia, Zaragoza)
Fuentes de datos integradas	3 (INE, SEPE, Municipal Open Data)
Cobertura temporal	2015 – 2023
Tablas en AWS Glue Data Catalog	10 tablas (Gold + Silver)
Tiempo medio de respuesta del chatbot	4 – 8 segundos (incluye Athena + Gemini)
Modelo de disponibilidad	Servicios gestionados, sin instancias persistentes propias
URL pública	<code>https://project-zcvjr.vercel.app</code>

3.10. Estimación de costes cloud

El modelo de coste de ISEU+ se basa en servicios de facturación por uso, sin infraestructura comprometida de forma permanente. La Tabla 3.2 presenta un escenario académico de bajo tráfico con unas 3.000 consultas mensuales y una ejecución mensual del pipeline. Es una aproximación: las tarifas, el nivel gratuito, los tokens del modelo y los bytes realmente escaneados pueden modificar el total.

Servicio	Concepto	Coste estimado/mes
Amazon S3	Almacenamiento ~500 MB Parquet	< 0,02 USD
Amazon Athena	~3.000 consultas × 10 KB escaneados	< 0,01 USD
AWS Lambda	~3.000 invocaciones × 3 s	< 0,01 USD
AWS Glue Data Catalog	Hasta 1 M de objetos catalogados	Gratuito
ECS Fargate	1 ejecución mensual, hasta 2 h, 1 vCPU / 4 GB	~ 0,12 USD
Amazon ECR	Almacenamiento imagen Docker ~300 MB	< 0,03 USD
Gemini 2.5 Flash API	Consumo de entrada y salida	Según tokens y plan vigente
Vercel	Plan Hobby (gratuito para proyectos académicos)	0,00 USD
Infraestructura estimada	Excluye consumo variable de Gemini	< 0,30 USD/mes

Tabla 3.2

Estimación de costes mensuales del sistema ISEU+ en producción.

Basada en el uso moderado descrito. Los servicios AWS incluidos en el nivel gratuito (Free Tier) durante los primeros 12 meses no se han contabilizado.

3.11. Conclusiones del despliegue cloud

La migración de ISEU+ a una arquitectura serverless en AWS y Vercel demuestra que es posible construir un sistema público con cobertura real y un coste de infraestructura muy reducido en el escenario académico medido. El modelo medallón en S3 garantiza la trazabilidad desde el dato crudo hasta el indicador publicado, mientras que Athena y Lambda permiten consultas SQL interactivas sin mantener un motor analítico permanentemente encendido.

El módulo conversacional basado en Gemini 2.5 Flash añade una capa de acceso en lenguaje natural: el usuario no necesita conocer el esquema ni SQL para formular una consulta. El flujo NL2SQL de dos fases (planificación estructurada y redacción con evidencia) busca reducir afirmaciones no respaldadas; las reglas del sistema exigen que las respuestas cuantitativas indiquen fuente, territorio y período, aunque esta propiedad debe verificarse mediante pruebas continuas.

Como líneas de trabajo futuro se identifican tres áreas prioritarias: (1) ampliar la cobertura con vivienda (MITMA/MIVAU) y energía (REE); (2) monitorizar la programación mensual ya desplegada y adaptar su calendario a cada publicación oficial; y (3) implementar dominio propio, autenticación, cuotas y presupuestos si el sistema evoluciona de demostración académica a servicio institucional.

Capítulo 4

Indicadores clave de rendimiento y escenario TO-BE

Este capítulo transforma los resultados técnicos de ISEU+ en un sistema de evaluación. Un KPI no es simplemente una cifra visible en un panel: es una medida vinculada a una pregunta, una regla de cálculo, una fuente, una periodicidad y un umbral que permite decidir. Se distinguen tres planos: los indicadores urbanos que describen las ciudades, los indicadores de calidad que describen los datos y los indicadores operativos que describen la plataforma. Esta separación evita confundir, por ejemplo, una mejora del desempleo de una ciudad con una mejora del tiempo de respuesta del sistema.

El escenario AS-IS corresponde al despliegue verificado al cierre del proyecto: siete ciudades, tres familias de fuentes, cobertura principal 2015–2023, 386.225 registros consultables en Athena, una aplicación pública en Vercel y un asistente NL2SQL basado en Gemini. El escenario TO-BE establece la evolución deseada sin presentar como terminado aquello que todavía es una línea futura. Todos los objetivos se formulan con horizonte, responsable y criterio de aceptación.

4.1. Marco de medicion

El marco de medicion adopta una cadena simple: dato, metrica, indicador, objetivo y decision. El dato es una observacion individual; la metrica es una operacion reproducible sobre observaciones; el indicador aporta contexto y comparabilidad; el objetivo fija el estado deseado; y la decision define que accion se activa cuando el valor se aparta del umbral. Esta cadena obliga a que cada tarjeta del dashboard pueda explicarse y reproducirse mediante SQL.

Para evitar indicadores decorativos se aplican cinco condiciones. Deben ser relevantes para una pregunta del proyecto, calculables con datos disponibles, comparables en el tiempo, trazables hasta una fuente oficial y accionables. Cuando una medida no cumple alguna condicion se mantiene como metadato exploratorio, no como KPI. Tambien se distingue entre valor observado y estimado: ISEU+ no interpola automaticamente periodos ausentes ni convierte una ausencia en cero.

Tabla 4.1

Ficha minima exigida para cada KPI.

Campo	Contenido requerido
Nombre y proposito	Pregunta que responde y usuario que toma la decision.
Formula	Expresion, filtros, agregacion y tratamiento de nulos.
Dimensiones	Territorio, periodo, fuente, variable y granularidad.
Calidad	Cobertura, actualidad, unicidad y limitaciones conocidas.
Objetivo	Linea base, umbral, horizonte y sentido de mejora.
Trazabilidad	Tabla Athena, columna, organismo y fecha de extraccion.

4.2. Línea base AS-IS

La línea base se obtiene de los artefactos generados por el pipeline y de las consultas que alimentan el dashboard. Athena contiene 386.225 filas considerando conjuntamente tablas Gold y Silver. La tabla `iseu_indicadores` aporta 93.944 observaciones normalizadas y `iseu_semantic_obs` 105.774 observaciones enriquecidas. La tabla compacta `iseu_indicators` contiene 4.358 filas para comparaciones rápidas a nivel urbano. Estas magnitudes no deben sumarse como si fueran personas o hechos independientes: varias tablas representan el mismo fenómeno con diferente nivel de detalle.

El catálogo analítico expone 22 nombres de variable en la tabla enriquecida. El catálogo compacto agrupa doce familias operativas; por ello ambas cifras son correctas dentro de su capa. La cobertura territorial general es de siete ciudades, aunque el detalle de distrito y barrio se concentra en Barcelona. La cobertura temporal declarada es 2015–2023, con ventanas diferentes por fuente. Esta asimetría constituye parte de la línea base y no un error que deba ocultarse.

Tabla 4.2

Línea base verificable del sistema al cierre del proyecto.

Dimension	Valor	Interpretacion
Filas consultables	386.225	Suma operativa de capas registradas, no hechos únicos.
Indicadores principales	93.944	Tabla normalizada de consumo analítico.
Observaciones semánticas	105.774	Contexto territorial y notas.
Gold compacto	4.358	Comparación rápida entre ciudades.
Variables analíticas	22	Nombres publicados por la capa enriquecida.
Ciudades	7	Cobertura inicial del producto.
Fuentes	3 familias	INE, SEPE y datos abiertos municipales.

4.3. KPIs urbanos de renta

La dimension de renta incluye renta bruta, renta disponible, renta mediana, renta por persona, renta por hogar y medidas por unidad de consumo. El KPI principal no debe reducirse a un promedio nacional ni mezclar unidades territoriales. Para cada ciudad se selecciona el ultimo periodo comun disponible cuando se realiza una comparacion transversal; para una serie temporal se conserva cada periodo publicado. La mediana complementa a la media porque reduce la influencia de valores extremos y aproxima mejor la posicion del hogar central.

La formula generica es $R_{c,t} = \sum_i v_{i,c,t} w_{i,c,t} / \sum_i w_{i,c,t}$ cuando existen ponderadores oficiales. Si la fuente ya publica el indicador agregado, ISEU+ no vuelve a ponderarlo: conserva el valor oficial y registra la unidad. El KPI de brecha entre ciudades se expresa como diferencia absoluta y como indice relativo respecto de la mediana del conjunto. El objetivo TO-BE es incorporar una regla automatica que bloquee comparaciones cuando los periodos no sean equivalentes y que muestre de forma visible el desfase temporal.

4.3.1. Criterios de lectura de la renta

Una renta mayor no implica por si sola mayor bienestar. El sistema debe contextualizarla con desigualdad, empleo y, en una etapa futura, vivienda. Tampoco es correcto interpretar una renta por hogar como renta por persona. Por eso las respuestas del chatbot incluyen unidad, territorio, periodo y fuente; si la pregunta es ambigua, el asistente selecciona una variable disponible y explicita el criterio utilizado.

Como criterio de aceptacion, cualquier respuesta cuantitativa sobre renta debe devolver al menos cinco campos de evidencia: ciudad o geografia, variable exacta, valor, unidad y periodo. Debe ademas conservar la fuente INE. En el TO-BE, las pruebas automaticas contendran preguntas con sinonimos y verificaran que la consulta no mezcle renta bruta con disponible ni media con mediana.

4.4. KPIs urbanos de desigualdad

El coeficiente de Gini y la relacion P80/P20 describen la distribucion, no el nivel de renta. El primero se aproxima a cero cuando la distribucion es mas igualitaria y aumenta con la concentracion. La relacion P80/P20 compara la renta acumulada o equivalente de los extremos de la distribucion segun la definicion de la operacion estadistica. ISEU+ conserva la denominacion y el valor publicados por el INE, evitando recalcularlos a partir de agregados insuficientes.

El KPI comparativo se presenta por ciudad y periodo. Para rankings se exige usar el ultimo periodo disponible de cada ciudad mediante una funcion de ventana, pero la interfaz debe avisar si esos ultimos periodos no coinciden. El objetivo no es etiquetar ciudades como buenas o malas, sino detectar brechas persistentes y facilitar preguntas reproducibles. En el TO-BE se añadira una vista conjunta renta–desigualdad que permita distinguir crecimiento inclusivo, estancamiento, polarizacion y mejora distributiva.

4.5. KPIs urbanos de empleo

Los indicadores de empleo disponibles son paro registrado, contratos registrados y demandantes de empleo. Son registros administrativos del SEPE y no equivalen a la tasa de paro de la Encuesta de Poblacion Activa. El dashboard y el asistente deben utilizar siempre la expresion “paro registrado” cuando esa sea la variable consultada. El valor absoluto sirve para seguir la carga administrativa, pero no permite comparar justamente ciudades de distinto tamaño sin una poblacion de referencia compatible.

El AS-IS muestra series y ultimos valores. El TO-BE incorpora razones por mil habitantes cuando numerador y denominador compartan periodo y ambito territorial. La formula sera $T_{c,t} = 1000 P_{c,t}/N_{c,t}$, donde P es el paro registrado y N la poblacion de referencia. Si falta el denominador del mismo periodo, el sistema no calculara la tasa. Para contratos se medira asimismo variacion interanual, distinguiendo flujo mensual de stock.

4.5.1. Alertas de mercado laboral

Se propone una alerta temprana cuando el paro registrado aumenta durante tres periodos consecutivos, siempre que la serie tenga frecuencia y cobertura suficientes. Otra alerta señalará una caída interanual de contratos superior al umbral definido por el analista. Estas alertas no son predicciones causales: son reglas descriptivas que invitan a revisar la fuente y el contexto.

El criterio TO-BE exige que toda alerta almacene la consulta SQL, los periodos comparados, el valor que activo el umbral y la fecha de generacion. Así se evita que una notificación sobreviva a una corrección posterior de los datos sin dejar rastro. Las alertas se mostrarán como apoyo a la decisión, nunca como diagnóstico automático.

4.6. KPIs urbanos de demografia, movilidad y seguridad vial

La poblacion total actua como indicador y como denominador potencial. Debe controlarse el año de referencia y la definicion territorial, ya que municipio y area metropolitana no son intercambiabiles. Los registros de movilidad, usuarios de bicicleta publica y accidentes de trafico aportan contexto urbano, pero actualmente proceden principalmente de Open Data BCN. Por tanto, no constituyen una base homogenea para clasificar las siete ciudades.

El KPI de cobertura territorial muestra el porcentaje de ciudades con observacion valida por variable y periodo. Esta medida hace visible el sesgo de disponibilidad. El TO-BE prioriza integrar fuentes municipales equivalentes de Madrid, Valencia, Sevilla, Zaragoza, Malaga y Bilbao antes de publicar rankings de movilidad. Para seguridad vial se propone normalizar por poblacion y, si la fuente lo permite, por volumen de desplazamientos, documentando la diferencia entre accidente, siniestro y persona afectada.

4.7. KPIs de cobertura y completitud

La completitud mide la proporción de valores presentes respecto de los esperados bajo una malla declarada de ciudad, variable y periodo. Su fórmula es $C = 100 n_{validos} / n_{esperados}$. El denominador no debe construirse suponiendo que todas las fuentes publican todas las combinaciones. Se deriva del contrato de cada conjunto: frecuencia, inicio, fin y ámbito. Un periodo aun no publicado no se clasifica como ausente.

Se calculan tres vistas: completitud global, por fuente y por variable. El umbral TO-BE es al menos 95 % para conjuntos con contrato estable y 90 % para fuentes municipales heterogeneas. Una caída de cinco puntos respecto de la ejecución anterior generara advertencia. La página de calidad mostrara las combinaciones ausentes para que el usuario pueda diferenciar un fallo de ingesta de una limitación original.

4.8. KPIs de actualidad

La actualidad se define como la distancia entre la fecha de publicacion o extraccion y el ultimo periodo disponible. No se usa un unico umbral porque una serie mensual del SEPE y una operacion anual del INE tienen calendarios distintos. El KPI de retraso se compara con el acuerdo de servicio de cada fuente: periodo esperado mas tolerancia. Esta formulacion evita marcar como obsoleta una estadistica anual publicada conforme a calendario.

El objetivo TO-BE es registrar `extracted_at`, `published_at` cuando exista y `period` en todas las tablas Gold. EventBridge ejecutara el pipeline mensualmente y el sistema comprobara si hubo novedades antes de sustituir el artefacto vigente. Si una fuente no cambia, la ejecucion se considera correcta pero se registra como “sin nueva version”.

4.9. KPIs de validez, consistencia y unicidad

La validez comprueba tipos, unidades, dominios y rangos. La consistencia verifica relaciones internas, como que una ciudad pertenezca al catalogo geografico o que el periodo tenga formato admitido. La unicidad controla que la clave logica de una observacion no se repita. Las claves incluyen fuente, conjunto, variable, geografia, periodo y, cuando procede, categoria. No se elimina un duplicado sin conservar una regla de resolucio

El TO-BE fija cero duplicados en Gold para la clave logica y al menos 99,5 % de filas validas. Un incumplimiento critico detendra la publicacion de Gold, aunque Bronze se conserve para diagnostico. Los resultados quedaran en **reports/** y los fallos irrecuperables en **errors/**. La regla refleja un principio: es preferible mantener la version anterior conocida que publicar silenciosamente una tabla corrupta.

4.10. KPIs de trazabilidad y reproducibilidad

La trazabilidad evalua si una cifra puede recorrer el camino inverso desde la interfaz hasta el objeto Bronze. Cada observacion Gold debe conservar fuente, conjunto, periodo, geografia y una referencia al origen o al informe de ejecucion. A nivel de proceso, la sincronizacion por SHA-256 permite identificar contenido repetido y evita cargas duplicadas. El codigo y la infraestructura versionados completan la evidencia.

El KPI de trazabilidad es el porcentaje de filas Gold con metadatos minimos no nulos. El objetivo es 100 %. La reproducibilidad se valida ejecutando el pipeline sobre una copia controlada de Bronze y comparando conteos, esquema y hashes de salida. Se acepta una diferencia solo si proviene de una dependencia no determinista documentada. Cada despliegue debe enlazar version de codigo, definicion de tarea y fecha de ejecucion.

4.11. KPIs operativos del pipeline

Los KPIs operativos cubren tasa de ejecuciones correctas, duracion, volumen descargado, objetos nuevos, objetos omitidos por hash y errores por fuente. CloudWatch Logs y los informes de `cloud_runs` son las fuentes de observabilidad. La linea base confirma una ejecucion integral en Fargate y la publicacion de las capas en S3; no existe todavia una serie historica suficiente para afirmar un percentil de disponibilidad anual.

El TO-BE fija exito mensual superior al 95 % en una ventana movil de doce ejecuciones, duracion inferior a dos horas para el volumen actual y alerta inmediata tras agotar dos reintentos. Una fuente externa caida puede registrarse como exito parcial si la politica `continue-on-error` esta activa, pero esa ejecucion no contara como completa para el KPI de frescura de la fuente afectada.

4.12. KPIs de consulta Athena y API

Para Athena se mediran tiempo de ejecucion, bytes escaneados, consultas correctas y consultas canceladas. Para Lambda se observaran invocaciones, errores, duracion, arranques en frio y respuestas por endpoint. El timeout del handler esta configurado a 22 segundos; por ello una consulta que excede ese limite se cancela activamente y se registra como fallo controlado.

Los objetivos TO-BE son un percentil 95 inferior a ocho segundos para `/dashboard`, inferior a cuatro segundos para consultas SQL simples y tasa de error menor al 1 % excluyendo peticiones invalidas. Los bytes escaneados deben mantenerse bajos mediante Parquet, seleccion de columnas y filtros. Un aumento sostenido desencadenara revision de particiones y del tamaño de archivos, no un incremento automatico de infraestructura.

4.13. KPIs del chatbot NL2SQL

La evaluación del asistente se separa en planificación, ejecución y respuesta. La exactitud de ejecución indica si el SQL produce el resultado esperado; la seguridad mide el rechazo de operaciones no permitidas; la fidelidad comprueba si la respuesta usa exclusivamente las filas recuperadas; y la trazabilidad comprueba si menciona fuente, territorio, periodo y unidad. La fluidez lingüística es secundaria frente a estas propiedades.

El TO-BE propone un banco versionado de al menos cien preguntas: saludos, consultas simples, comparaciones, series temporales, geografía de barrio, variables inexistentes e intentos adversariales. Los umbrales son 90 % de exactitud de ejecución en preguntas soportadas, 100 % de bloqueo de DDL/DML en el conjunto adversarial y cero afirmaciones cuantitativas no respaldadas. Cada cambio de modelo o prompt ejecutará el banco antes del despliegue.

4.13.1. Latencia y experiencia conversacional

La latencia percibida incluye planificacion con Gemini, consulta Athena, redaccion final y transmision SSE. El streaming reduce el tiempo hasta el primer texto aunque no reduzca el tiempo total. Se mediran tiempo hasta primer evento, tiempo hasta primer token, tiempo total y abandonos. El objetivo TO-BE es primer estado visible antes de un segundo y respuesta completa en menos de diez segundos para el percentil 95 de preguntas simples.

La interfaz ya presenta estados como “Pensando”, “Recuperando datos” y “Generando respuesta”. En la evolucion se mostrara tambien si se consultaron datos y cuantas filas sustentan la respuesta, sin revelar razonamiento interno ni secretos. Cuando Athena no devuelva filas, el asistente debe decirlo de forma explicita en lugar de completar el hueco con conocimiento general.

4.14. KPIs de producto y accesibilidad

Los indicadores de producto incluyen sesiones, preguntas por sesion, porcentaje de consultas con datos, uso de tablas y graficos, errores visibles y retorno de usuarios. No se almacenara el contenido completo de las preguntas por defecto; la analitica debe ser agregada y respetar minimizacion de datos. Para un TFM, el exito inicial se valida con pruebas de tareas y no con crecimiento comercial.

La accesibilidad se evaluara mediante navegacion por teclado, contraste, textos alternativos, foco visible y adaptacion movil. El TO-BE busca conformidad WCAG 2.1 nivel AA en las vistas principales y una tasa de finalizacion de tareas superior al 85 % en una prueba con usuarios. Las tarjetas del dashboard deben conservar significado sin depender exclusivamente del color.

4.15. KPIs de coste y eficiencia

El coste se expresa por mes, por ejecucion del pipeline y por mil consultas. La arquitectura evita instancias permanentes: S3 cobra almacenamiento y solicitudes, Athena datos escaneados, Lambda invocacion y duracion, Fargate recursos durante la tarea, y Gemini segun tokens y plan vigente. Las cifras del capitulo de arquitectura son estimaciones bajo un escenario concreto, no una tarifa garantizada.

El TO-BE incorpora presupuestos y alertas en AWS, limites de consultas, registro de bytes escaneados y seguimiento del consumo de Gemini. El objetivo inicial es mantener el coste de infraestructura por debajo de 5 USD al mes durante la fase academica, dejando margen respecto del consumo observado. Si el uso crece, se comparara coste por consulta antes de cambiar a servicios con capacidad reservada.

4.16. Cuadro de mando de objetivos

Tabla 4.3

Objetivos TO-BE y criterios de aceptacion.

KPI	Linea base	Objetivo	Evidencia
Cobertura urbana	7 ciudades	10 ciudades	Catalogo y filas Gold.
Variables	22 analiticas	≥ 30	Esquema Glue y catalogo.
Compleitud estable	Por medir historicamente	$\geq 95\%$	Informe por ejecucion.
Duplicados Gold	Control de pipeline	0	Prueba de clave logica.
Exito mensual	Sin serie anual	$\geq 95\%$	CloudWatch y reports.
SQL correcto	Pruebas manuales	$\geq 90\%$	Banco de 100 preguntas.
SQL peligroso	Validador activo	100 % bloqueado	Suite adversarial.
Trazabilidad Gold	Metadatos disponibles	100 %	Auditoria de campos.
Coste academico	Bajo pago por uso	< 5 USD/mes	AWS Budgets y facturas.
Accesibilidad	Revision visual	WCAG AA	Auditoria automatica/manual.

4.17. Arquitectura objetivo TO-BE

La arquitectura objetivo conserva el nucleo serverless porque el volumen no justifica un almacen analitico permanente. Fargate seguira ejecutando la extraccion y transformacion; S3 mantendra Bronze, Silver y Gold; Glue catalogara; Athena consultara; Lambda expondra una superficie minima; Vercel servira la experiencia; y Gemini planificara y redactara con evidencia. La evolucion se centra en gobierno, pruebas y observabilidad, no en sustituir componentes que ya cumplen su funcion.

Se incorporaran contratos de datos por fuente, un manifesto de versiones, pruebas de calidad antes de promover Gold, alarmas de CloudWatch, presupuestos, y una suite NL2SQL en integracion continua. La API adoptara autenticacion y cuotas si el servicio deja de ser una demostracion publica. Las tablas se particionaran cuando el historial y los bytes escaneados demuestren que la mejora compensa el aumento de complejidad.

4.18. Hoja de ruta por horizontes

Horizonte 1, estabilizacion (0–3 meses). Consolidar informes de ejecucion, corregir documentacion operativa, automatizar pruebas de esquema y calidad, crear alarmas y medir una linea base real de latencia. Formalizar el banco NL2SQL y revisar accesibilidad.

Horizonte 2, ampliacion (3–6 meses). Integrar vivienda y energia cuando las licencias y formatos lo permitan, ampliar portales municipales, alcanzar diez ciudades y normalizar denominadores. Añadir vistas comparables de coste residencial y transicion energetica sin mezclarlas prematuramente en un indice unico.

Horizonte 3, madurez (6–12 meses). Implantar gobierno de datos, versionado de contratos, panel de observabilidad, autenticacion y evaluacion continua del modelo. Estudiar un indice compuesto solo despues de validar ponderaciones con expertos y analisis de sensibilidad.

4.19. Riesgos y respuestas

Tabla 4.4

Matriz resumida de riesgos del TO-BE.

Riesgo	Prob.	Impacto	Respuesta
Cambio de API oficial	Media	Alta	Contrato, pruebas y conservacion de Bronze.
Periodos no comparables	Alta	Alta	Ultimo periodo comun y aviso visible.
SQL incorrecto del LLM	Media	Alta	Esquema cerrado, validador y banco de pruebas.
Consulta costosa	Baja	Media	Limites, Parquet y metrica de bytes.
Clave expuesta	Baja	Alta	Secretos de entorno, rotacion y minimo privilegio.
Sesgo territorial	Alta	Media	KPI de cobertura y ampliacion antes de rankings.
Dependencia de proveedor	Media	Media	Interfaces simples, datos en formatos abiertos.

4.20. Gobernanza, responsables y cadencia

Cada dominio necesita un responsable. El propietario de datos valida definiciones y fuentes; el responsable tecnico mantiene conectores e infraestructura; el responsable de calidad revisa informes y autoriza la promocion; y el propietario de producto prioriza necesidades de usuarios. En un proyecto individual una persona puede asumir varios roles, pero la distincion evita que una decision tecnica se presente como decision metodologica.

La cadencia propuesta es mensual para ingesta y revision operativa, trimestral para catalogo y objetivos, y semestral para arquitectura y costes. Los cambios de fuente o formula requieren registro de decision. Un KPI solo entra en produccion cuando tiene ficha, consulta reproducible, prueba y texto de limitaciones.

4.21. Criterios de aceptacion del escenario futuro

El TO-BE se considerara alcanzado cuando exista evidencia acumulada, no solo componentes desplegados. Deben completarse doce ejecuciones mensuales con informes, diez ciudades con un nucleo comparable, al menos treinta variables catalogadas, pruebas automaticas de calidad y un banco NL2SQL con resultados por version. La API debe mantener los umbrales de error y latencia y el coste debe estar cubierto por alertas.

Tambien se exige que la documentacion diferencie dato oficial, transformacion propia e inferencia del modelo. La interfaz debe mostrar fuente, periodo y unidad; las limitaciones territoriales deben ser visibles; y un usuario debe poder reproducir una cifra mediante una consulta guardada. Estos criterios convierten la evolucion tecnologica en una mejora verificable del producto academico.

4.22. Sintesis

El sistema ya resuelve el recorrido completo desde fuentes oficiales hasta una consulta conversacional publica. Sus principales fortalezas son la trazabilidad por capas, el pago por uso, la consulta SQL sobre formatos abiertos y la separacion entre planificacion del modelo y ejecucion segura. Sus principales limites son la heterogeneidad territorial, la ausencia de una serie operativa larga y la necesidad de evaluar sistematicamente el NL2SQL.

Los KPIs propuestos permiten gestionar esas limitaciones sin ocultarlas. El escenario TO-BE no consiste en añadir servicios por inercia, sino en aumentar cobertura comparable, calidad, reproducibilidad y evidencia. La arquitectura solo debera cambiar cuando las mediciones demuestren que el volumen, la latencia, el coste o el gobierno ya no pueden resolverse adecuadamente con el diseño actual.

Bibliografía

- Ajuntament de Barcelona. (2023). *Open Data BCN*. Consultado el 29 de junio de 2026, desde <https://opendata-ajuntament.barcelona.cat/>
- Amazon Web Services. (2023a). *Amazon Elastic Container Service Documentation*. Consultado el 29 de junio de 2026, desde <https://docs.aws.amazon.com/AmazonECS/latest/developerguide/Welcome.html>
- Amazon Web Services. (2023b). *Amazon EventBridge Scheduler User Guide*. Consultado el 29 de junio de 2026, desde <https://docs.aws.amazon.com/scheduler/latest/UserGuide/what-is-scheduler.html>
- Amazon Web Services. (2023c). *AWS Fargate for Amazon ECS*. Consultado el 29 de junio de 2026, desde https://docs.aws.amazon.com/AmazonECS/latest/developerguide/AWS_Fargate.html
- Amazon Web Services. (2023d). *What Is Amazon Athena?* Consultado el 29 de junio de 2026, desde <https://docs.aws.amazon.com/athena/latest/ug/what-is.html>
- Amazon Web Services. (2023e). *What Is Amazon Elastic Container Registry?* Consultado el 29 de junio de 2026, desde <https://docs.aws.amazon.com/AmazonECR/latest/userguide/what-is-ecr.html>
- Amazon Web Services. (2023f). *What Is Amazon S3?* Consultado el 29 de junio de 2026, desde <https://docs.aws.amazon.com/AmazonS3/latest/userguide/Welcome.html>
- Amazon Web Services. (2023g). *What Is AWS Glue?* Consultado el 29 de junio de 2026, desde <https://docs.aws.amazon.com/glue/latest/dg/what-is-glue.html>
- Amazon Web Services. (2023h). *What Is AWS Lambda?* Consultado el 29 de junio de 2026, desde <https://docs.aws.amazon.com/lambda/latest/dg/welcome.html>
- Amazon Web Services. (2024a). *Data Lakes on AWS*. Consultado el 29 de junio de 2026, desde <https://docs.aws.amazon.com/solutions/data-lakes-on-aws/>

- Amazon Web Services. (2024b). *Security Best Practices in IAM*. Consultado el 29 de junio de 2026, desde <https://docs.aws.amazon.com/IAM/latest/UserGuide/best-practices.html>
- Amazon Web Services. (2024c). *What Is Amazon CloudWatch?* Consultado el 29 de junio de 2026, desde <https://docs.aws.amazon.com/AmazonCloudWatch/latest/monitoring/WhatIsCloudWatch.html>
- Amazon Web Services. (2026). *Boto3 Documentation*. Consultado el 29 de junio de 2026, desde <https://boto3.amazonaws.com/v1/documentation/api/latest/index.html>
- Apache Software Foundation. (2023). *Apache Parquet Documentation*. Consultado el 29 de junio de 2026, desde <https://parquet.apache.org/docs/>
- Armbrust, M., et al. (2010). A View of Cloud Computing. *Communications of the ACM*, 53(4), 50-58. <https://doi.org/10.1145/1721654.1721672>
- Batty, M. (2013). *The New Science of Cities*. MIT Press.
- Brown, T. B., et al. (2020). Language Models Are Few-Shot Learners. *Advances in Neural Information Processing Systems*, 33, 1877-1901.
- Databricks. (2021). *What Is a Medallion Architecture?* Consultado el 29 de junio de 2026, desde <https://www.databricks.com/glossary/medallion-architecture>
- Davenport, T. H., Barth, P., & Bean, R. (2012). How Big Data Is Different. *MIT Sloan Management Review*, 54(1), 22-24.
- Dixon, J. (2010). *Pentaho, Hadoop, and Data Lakes*. Consultado el 29 de junio de 2026, desde <https://jamesdixon.wordpress.com/2010/10/14/pentaho-hadoop-and-data-lakes/>
- Docker. (2026). *Docker Documentation*. Consultado el 29 de junio de 2026, desde <https://docs.docker.com/>
- European Parliament and Council. (2016). *Regulation (EU) 2016/679*. Consultado el 29 de junio de 2026, desde <https://eur-lex.europa.eu/eli/reg/2016/679/oj>
- European Parliament and Council. (2019). *Directive (EU) 2019/1024 on Open Data and the Re-use of Public Sector Information*. Consultado el 29 de junio de 2026, desde <https://eur-lex.europa.eu/eli/dir/2019/1024/oj>
- Eurostat. (2023). *City Statistics: Urban Audit*. Consultado el 29 de junio de 2026, desde <https://ec.europa.eu/eurostat/web/cities>

- Glaeser, E. L. (2011). *Triumph of the City*. Penguin Press.
- Google. (2024). *Gemini API Documentation*. Consultado el 29 de junio de 2026, desde <https://ai.google.dev/gemini-api/docs>
- Google. (2026a). *Gemini API Pricing*. Consultado el 29 de junio de 2026, desde <https://ai.google.dev/gemini-api/docs/pricing>
- Google. (2026b). *Structured Outputs in the Gemini API*. Consultado el 29 de junio de 2026, desde <https://ai.google.dev/gemini-api/docs/structured-output>
- Guo, J., et al. (2019). Towards Complex Text-to-SQL in Cross-Domain Database with Intermediate Representation. *Proceedings of ACL*, 4524-4535. <https://doi.org/10.18653/v1/P19-1444>
- IBM. (2012). *The Four V's of Big Data*. Consultado el 29 de junio de 2026, desde <https://www.ibm.com/>
- Inmon, W. H. (2016). *Data Lake Architecture*. Technics Publications.
- Instituto Nacional de Estadística. (2022). *API de consulta de datos INE*. Consultado el 29 de junio de 2026, desde <https://www.ine.es/dyngs/DataLab/manual.html?cid=45>
- Instituto Nacional de Estadística. (2023a). *Atlas de distribución de renta de los hogares*. Consultado el 29 de junio de 2026, desde https://www.ine.es/dyngs/INEbase/operacion.htm?c=Estadistica_C&cid=1254736177088&idp=1254735976608&menu=metodologia
- Instituto Nacional de Estadística. (2023b). *El INE: funciones y organización*. Consultado el 29 de junio de 2026, desde <https://www.ine.es/>
- Instituto Nacional de Estadística. (2023c). *Estadística del Padrón Continuo*. Consultado el 29 de junio de 2026, desde <https://www.ine.es/>
- Instituto Nacional de Estadística. (2023d). *Metodología del Atlas de distribución de renta de los hogares*. Consultado el 29 de junio de 2026, desde https://www.ine.es/metodologia/metodologia_adrh.pdf
- JSON-stat. (2023). *JSON-stat Format*. Consultado el 29 de junio de 2026, desde <https://json-stat.org/>
- Kimball, R., & Ross, M. (2013). *The Data Warehouse Toolkit* (3.^a ed.). Wiley.
- Kitchin, R. (2014). *The Data Revolution*. SAGE.

- Kleppmann, M. (2017). *Designing Data-Intensive Applications*. O'Reilly Media.
- Laney, D. (2001). 3D Data Management: Controlling Data Volume, Velocity, and Variety. *META Group Research Note*.
- Li, J., et al. (2023). Can LLM Already Serve as a Database Interface? A Big Bench for Large-Scale Database Grounded Text-to-SQLs. *arXiv preprint arXiv:2305.03111*.
- Pinheiro, L. C., et al. (2019). The City Health Dashboard: A New Resource for Urban Health Policy. *Journal of Urban Health*, 96, 612-621. <https://doi.org/10.1007/s11524-019-00376-10>
- Pipino, L. L., Lee, Y. W., & Wang, R. Y. (2002). Data Quality Assessment. *Communications of the ACM*, 45(4), 211-218. <https://doi.org/10.1145/505248.506010>
- Python Software Foundation. (2026). *Python 3.12 Documentation*. Consultado el 29 de junio de 2026, desde <https://docs.python.org/3.12/>
- Roberts, M. (2018). Serverless Architectures. *Martin Fowler*. Consultado el 29 de junio de 2026, desde <https://martinfowler.com/articles/serverless.html>
- Servicio Público de Empleo Estatal. (2023). *Estadísticas de empleo*. Consultado el 29 de junio de 2026, desde <https://www.sepe.es/HomeSepe/que-es-el-sepe/estadisticas.html>
- Trino Software Foundation. (2026). *Trino SQL Language*. Consultado el 29 de junio de 2026, desde <https://trino.io/docs/current/language.html>
- Vaswani, A., et al. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems*, 30.
- Vercel. (2023). *Vercel Documentation*. Consultado el 29 de junio de 2026, desde <https://vercel.com/docs>
- Wang, R. Y., & Strong, D. M. (1996). Beyond Accuracy: What Data Quality Means to Data Consumers. *Journal of Management Information Systems*, 12(4), 5-33. <https://doi.org/10.1080/07421222.1996.11518099>
- Wei, J., et al. (2022). Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. *Advances in Neural Information Processing Systems*, 35, 24824-24837.
- Wilkinson, M. D., et al. (2016). The FAIR Guiding Principles for Scientific Data Management and Stewardship. *Scientific Data*. <https://doi.org/10.1038/sdata.2016.18>

World Wide Web Consortium. (2018). *Web Content Accessibility Guidelines 2.1*. Consultado el 29 de junio de 2026, desde <https://www.w3.org/TR/WCAG21/>

Yu, T., et al. (2018). Spider: A Large-Scale Human-Labeled Dataset for Complex and Cross-Domain Semantic Parsing and Text-to-SQL Task. *Proceedings of EMNLP*, 3911-3921. <https://doi.org/10.18653/v1/D18-1425>